ЦИФРОВАЯ АКАДЕМИЯ

АРХИТЕКТУРА POSTGRESQL

Обучающий курс для разработчиков

Вебинар №1

Эксперт курса

ЦИФРОВАЯ АКАДЕМИЯ

Максим Щёткин

- С 2008 г. – Certified Cisco Systems Instructor
- С 2012 г. – Oracle Certified Expert: Oracle Database SQL
- С 2016 г. разработчик и преподаватель авторских курсов PostgreSQL
- С 2018 г. Авторизованный инструктор PostgreSQL
- С 2020 г. Сертифицированный инструктор AstraLinux

Цель вебинара

ЦИФРОВАЯ АКАДЕМИЯ

01

Получить необходимую информацию о сервере баз данных PostgreSQL

02

Понимать как серверный код выполняется в базе данных

03

Понимать как писать код, который эффективно отрабатывает в PostgreSQL

Интерактив

ЦИФРОВАЯ АКАДЕМИЯ

- Есть ли опыт по разработке серверного кода?
- Каковы ожидания от вебинара?
- Есть ли назревшие вопросы по теме вебинара?

содержание

ЦИФРОВАЯ АКАДЕМИЯ

1. Экземпляр
2. Транзакции
3. Фазы выполнения запросов, оптимизатор
4. Структура страницы
5. Многоверсионность (MVCC)
6. Задача очистки

ЦИФРОВАЯ АКАДЕМИЯ

№1

Экземпляр

Экземпляр

Экземпляр (Instance) –
это совокупность процессов
и структур памяти,
работающих совместно
для управления кластером
реляционных баз данных

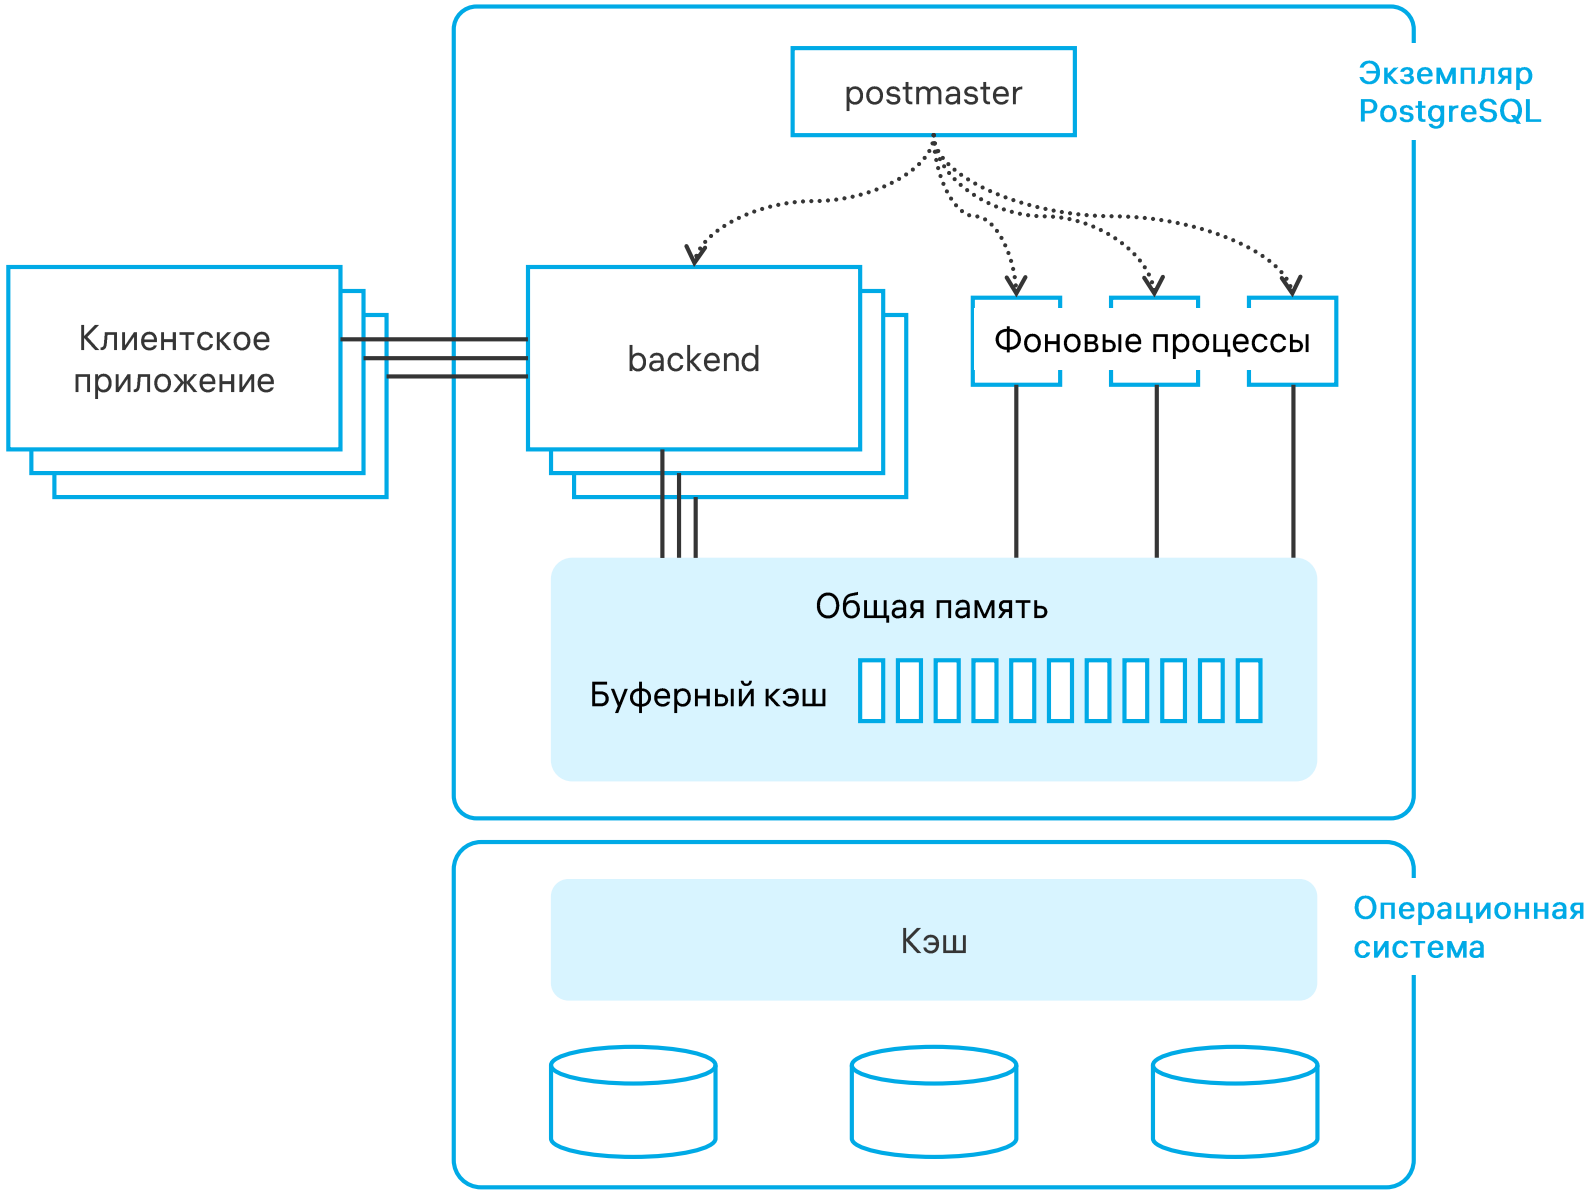

Сервер базы данных

ЦИФРОВАЯ АКАДЕМИЯ

psql Client

Соединение

Postmaster

Аутентификация/Авторизация/ Подключение на порт 5432 и порождение серверного процесса на каждое соединение

Серверный процесс

User Backend Process

Один серверный процесс на соединение

Память системы

Разделяемая память

Shared Buffers

WAL Buffers

CLOG Buffers

Lock Space

Other Buffers

Память серверного процесса

maintenance_work_mem
temp_buffer
work_mem
catalog cache
optimizer/executor

Кэш ОС

Обозначения

- взаимозависимые процессы
- соединение
- запрос на соединение
- серверный процесс

Фоновые процессы

BGWRITER | WAL Writer | AUTOVACUUM

STATS COLLECTOR | SYS LOGGER | ARCHIVER

WAL Sender ⟷ WAL Receiver

Экземпляр PostgreSQL
(Memory + Postmaster + User Backend Process + Utility Process)

Data Directory
/opt/PostgreSQL/9.0/data

Subdirectorie

base – папка табличного пространства pg_default
global – директория с глобальной информацией для кластера
pg_wal(pg_xlog) – журналы WAL
pg_multixact – статусы мультитранзакций
pg_subtrans – данные вложенных транакций
pg_stat_tmp – временные файлы подсистемы сбора статистик
pg_twophase – статус подготовленных транзакций

Configuration Files

postgresql.conf - конфигурационный файл
pg_hba.conf - файл аутентификации
pg_ident.conf - файл правил для внешней аутентификации

Lock Files

postmaster.pid - файл блокировка с PID и сегментом общей памяти (не присутствует после останова)
postmaster.opts - файл опций командной строки последнего запуска

Структура кластера PostgreSQL 9.0
(папки + конфигурационные файлы + файлы блокировок)

Процессы

ЦИФРОВАЯ АКАДЕМИЯ

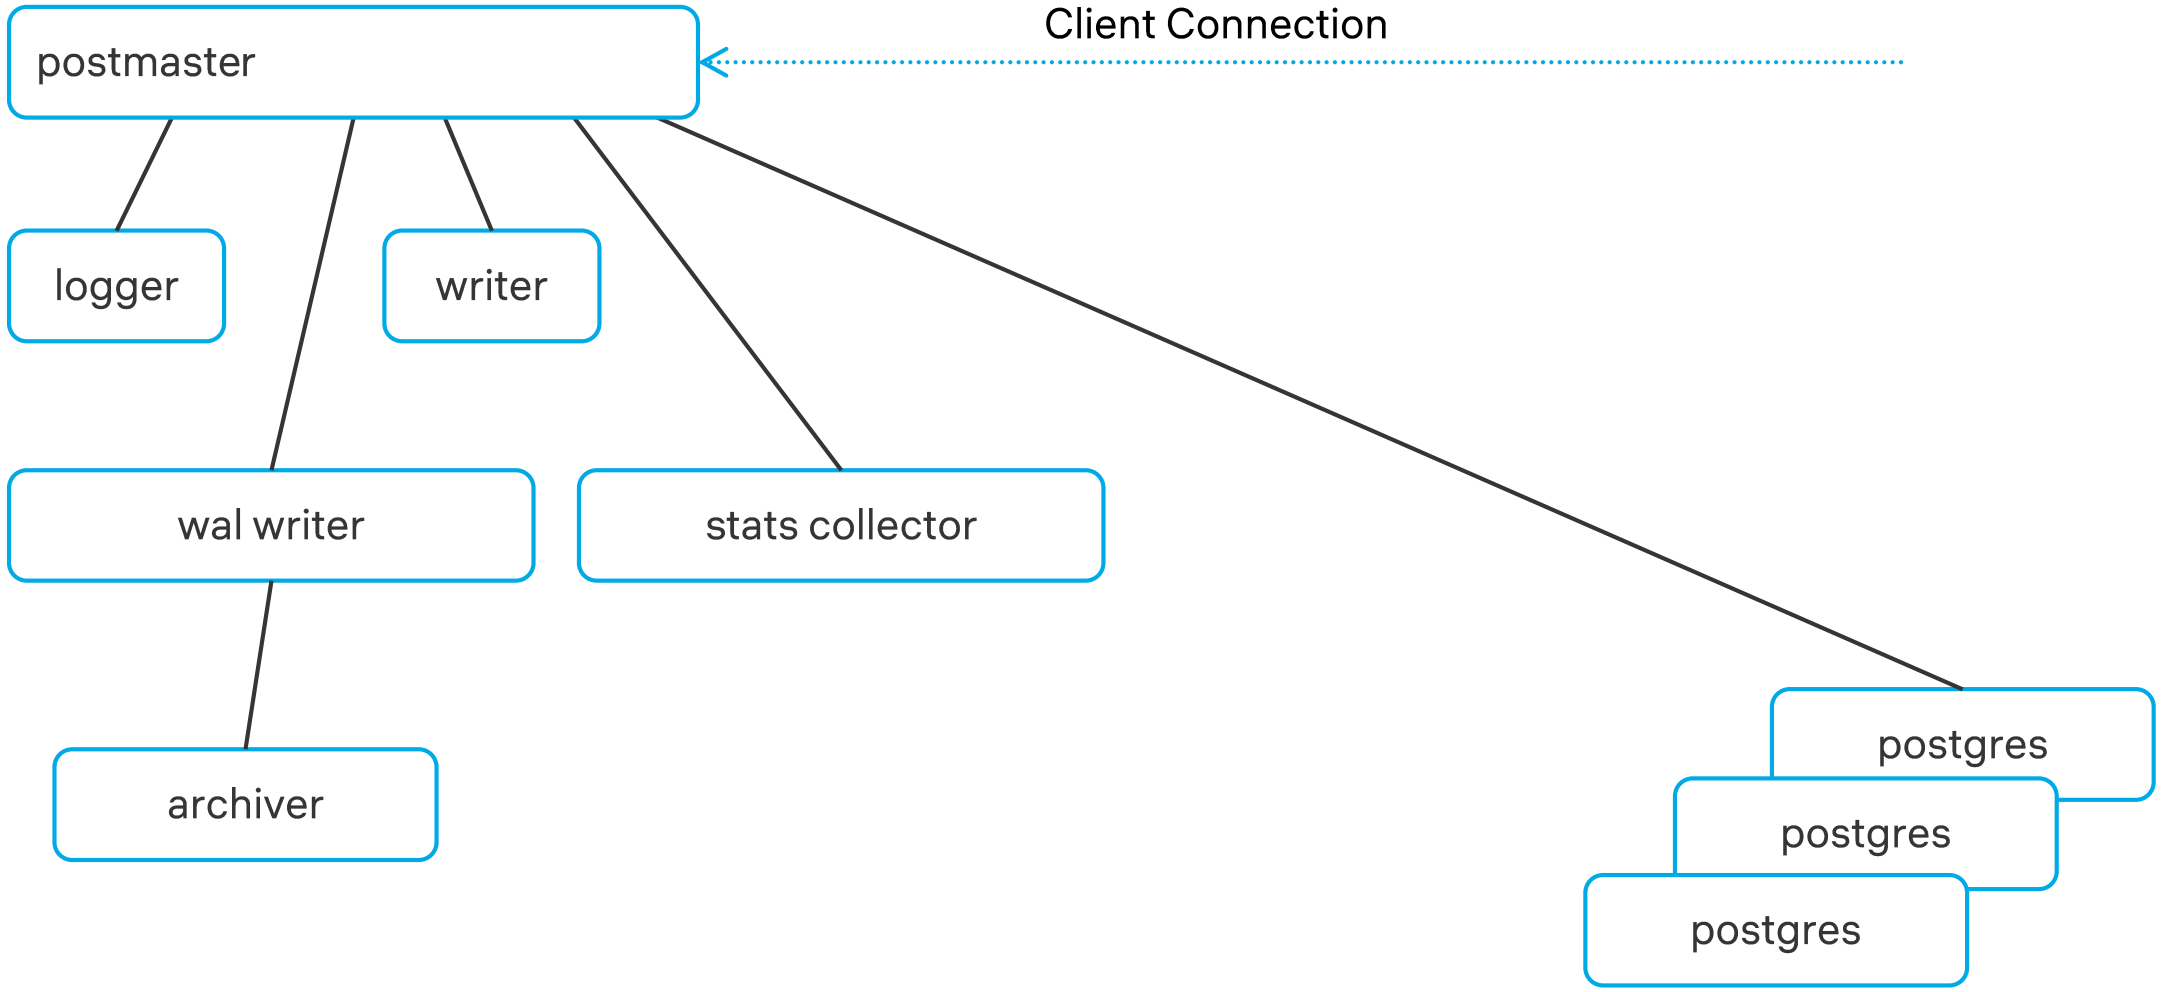

Процессы

ЦИФРОВАЯ АКАДЕМИЯ

- при старте сервера запускается процесс postgres, традиционно называемый **postmaster**
- **postmaster** запускает все остальные процессы (fork)
- **postmaster** «присматривает» за ними — если какой-нибудь процесс завершится аварийно, postmaster перезапустит его (или весь сервер, если сочтет, что процесс мог повредить общие данные)

Служебные процессы

ЦИФРОВАЯ АКАДЕМИЯ

- **startup** восстанавливает систему после сбоев
- **autovacuum** очищает таблицы от неактуальных данных
- **wal writer** записывает на диск журнальные записи
- **checkpointer** выполняет контрольную точку
- **writer** записывает грязные страницы на диск
- **stats collector** собирает статистику использования экземпляра
- **wal sender** передает журнальные записи на реплику
- **wal receiver** принимает журнальные записи на реплике

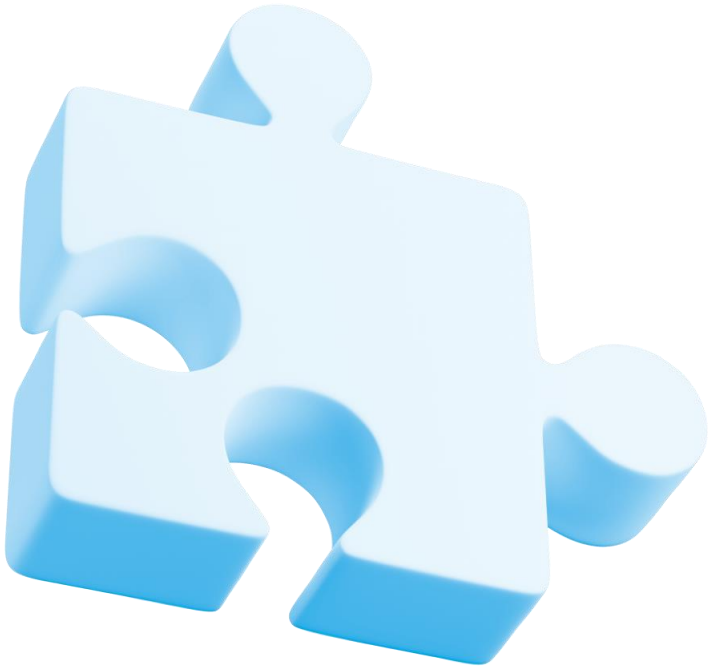

Структуры памяти

ЦИФРОВАЯ АКАДЕМИЯ

Диски (особенно HDD, но и SSD тоже) работают значительно медленнее, чем оперативная память, применяется кеширование

Буферный кеш занимает бóльшую часть общей памяти (shared_buffers)

PostgreSQL обычно не использует прямой ввод-вывод в обход механизмов операционной системы, поэтому кеширование получается двойным (effective_cache_size)

Для возможности восстановить согласованность данных, в процессе работы PostgreSQL ведет журнал предзаписи (WAL)

Структуры памяти

ЦИФРОВАЯ АКАДЕМИЯ

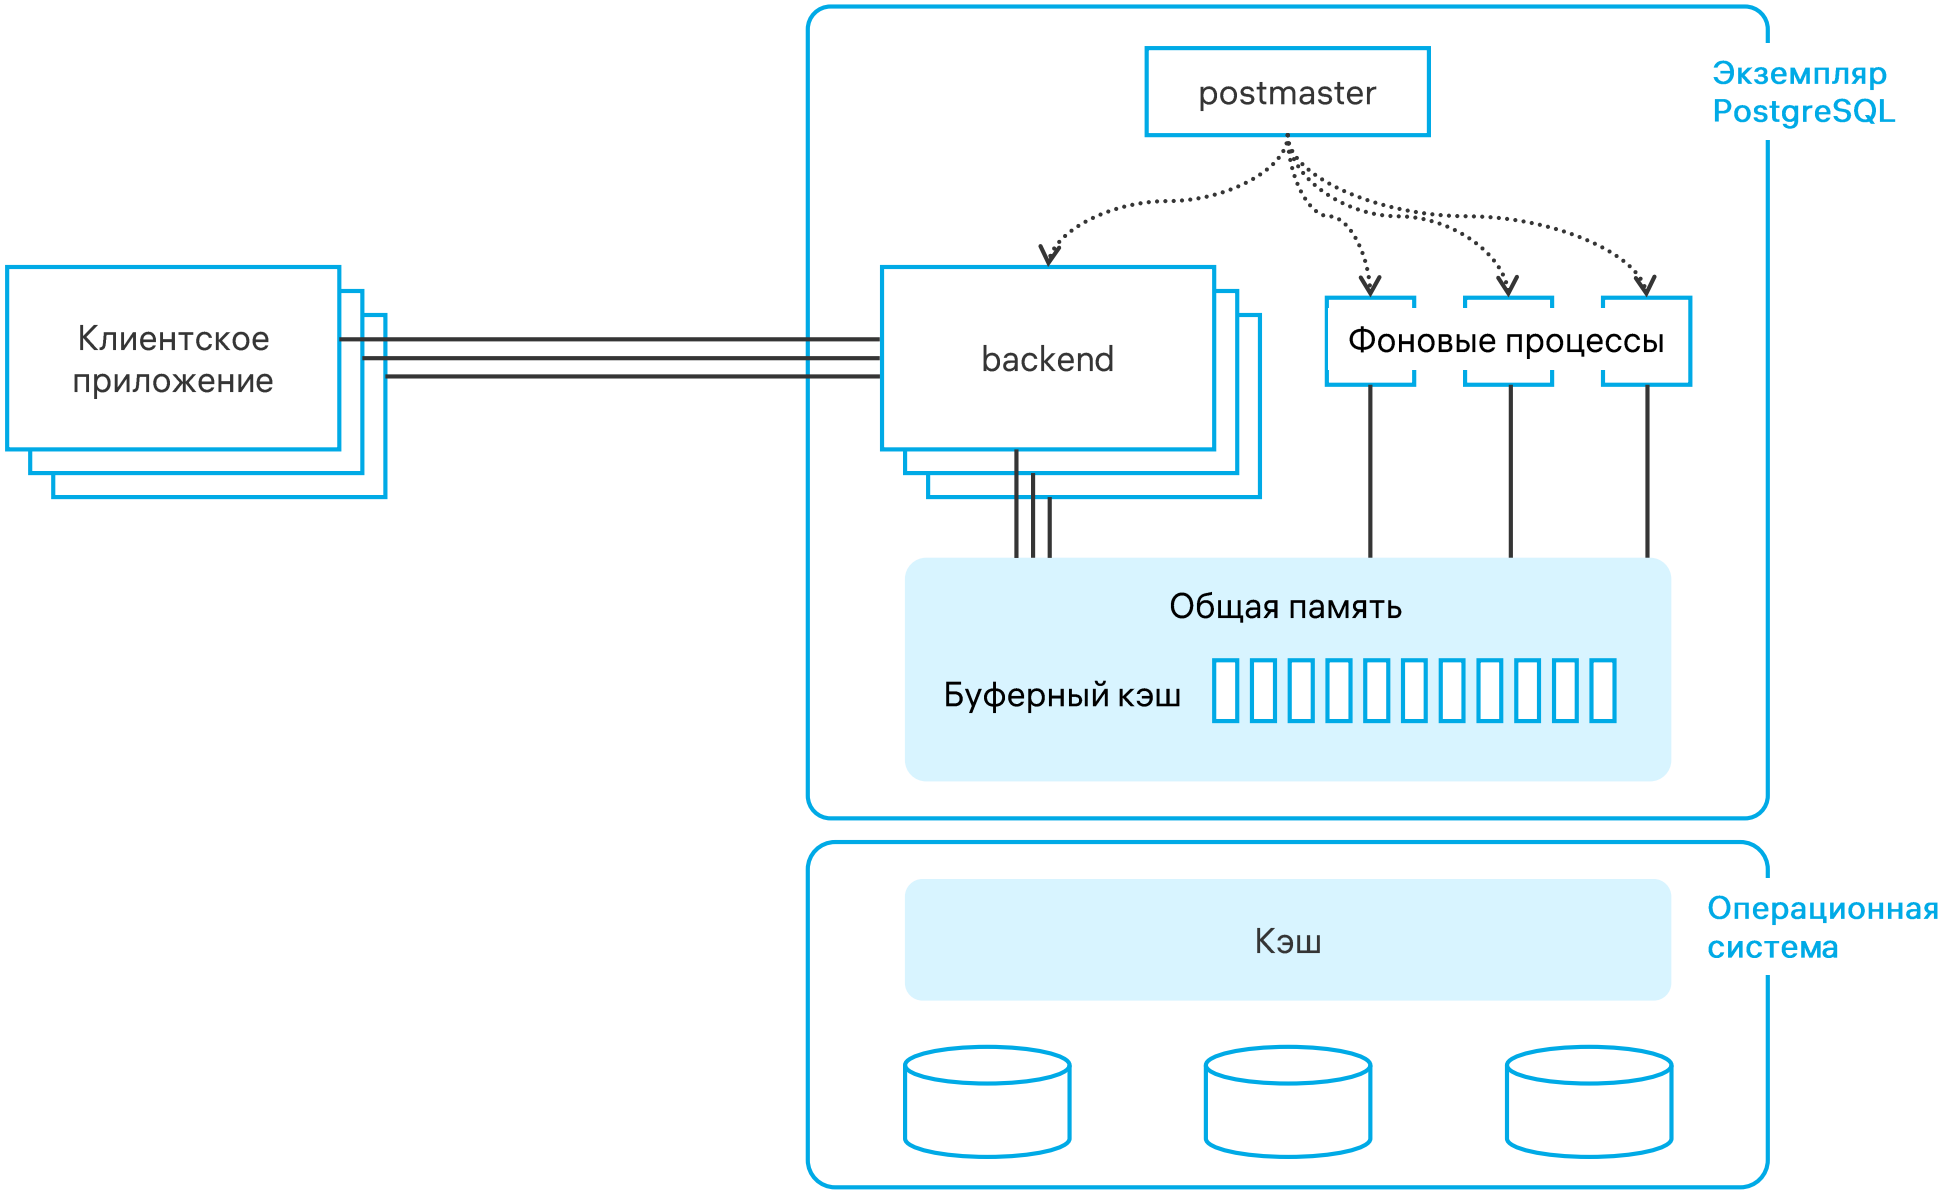

Общая память

ЦИФРОВАЯ АКАДЕМИЯ

Общая память используется для:

- взаимодействия между postmaster и серверными процессами
- разделения общих данных между серверными процессами
- кэширования страниц

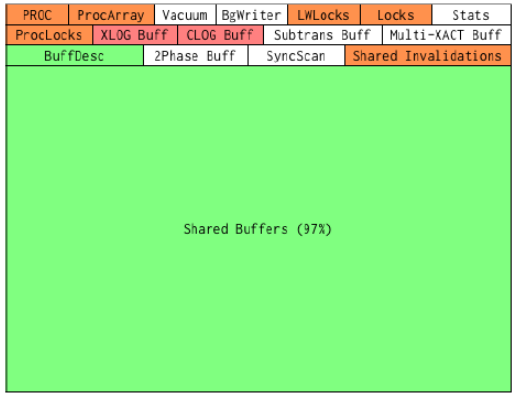

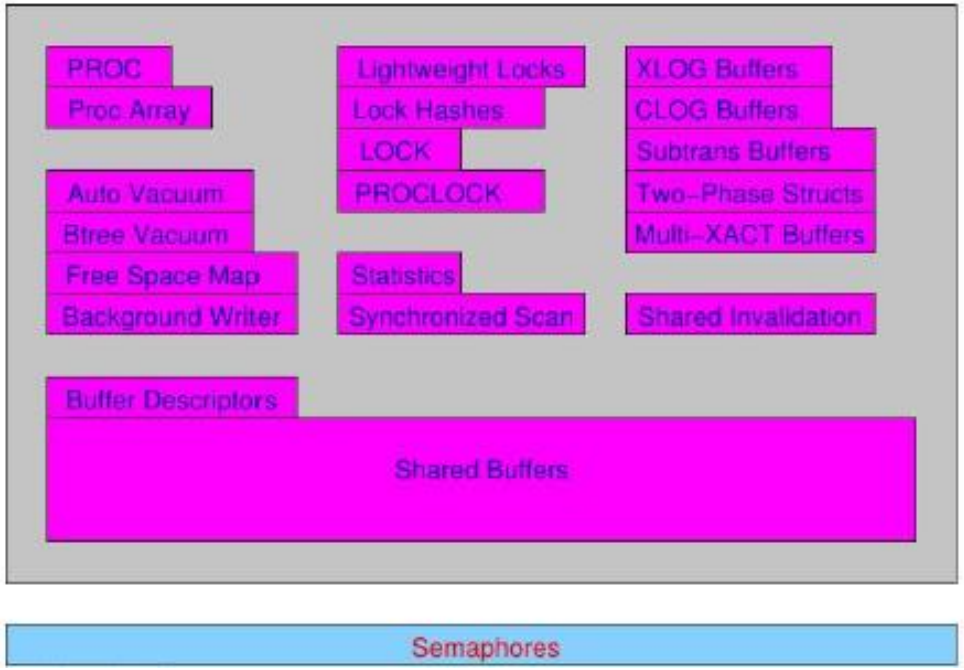

Кластер баз данных

ЦИФРОВАЯ АКАДЕМИЯ

PGDATA

- базовая директория сервера БД, содержит конфигурационные файлы и файлы данных
- пример расположения, /var/lib/pgsql/data
- несколько кластеров, управляемых различными экземплярами, могут сосуществовать на одном узле
- расположение конфигурационных файлов и файла pid можно изменить

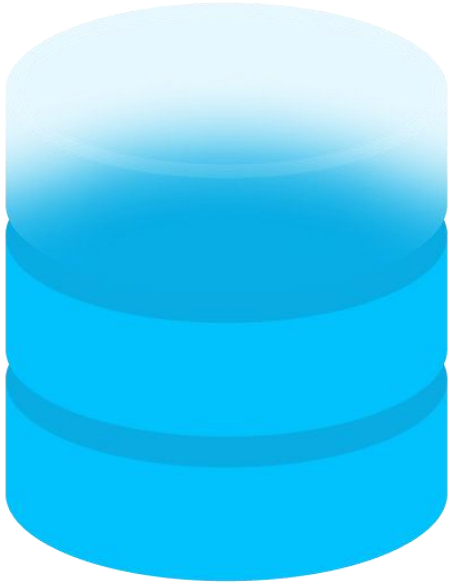

Содержание каталога PGDATA

ЦИФРОВАЯ АКАДЕМИЯ

Элемент	Описание
PG_VERSION	Файл, содержащий номер основной версии PostgreSQL
base	Подкаталог, содержащий подкаталоги для каждой базы данных
current_logfiles	Файл, в котором отмечается, в какие файлы журналов производит запись сборщик сообщений
global	Подкаталог, содержащий общие таблицы кластера, такие как pg_database
pg_commit_ts	Подкаталог, содержащий данные о времени фиксации транзакций
pg_dynshmem	Подкаталог, содержащий файлы, используемые подсистемой динамически разделяемой памяти
pg_logical	Подкаталог, содержащий данные о состоянии для логического декодирования
pg_multixact	Подкаталог, содержащий данные о состоянии мультитранзакций (используемые для разделяемой блокировки строк)
pg_notify	Подкаталог, содержащий данные состояния прослушивания и уведомлений (LISTEN/NOTIFY)
pg_replslot	Подкаталог, содержащий данные слота репликации
pg_serial	Подкаталог, содержащий информацию о выполненных сериализуемых транзакциях.
pg_snapshots	Подкаталог, содержащий экспортированные снимки (snapshots)
pg_stat	Подкаталог, содержащий постоянные файлы для подсистемы статистики.
pg_stat_tmp	Подкаталог, содержащий временные файлы для подсистемы статистики
pg_subtrans	Подкаталог, содержащий данные о состоянии подтранзакций
pg_tblspc	Подкаталог, содержащий символические ссылки на табличные пространства
pg_twophase	Подкаталог, содержащий файлы состояний для подготовленных транзакций
pg_wal	Подкаталог, содержащий файлы WAL (журнал предзаписи)
pg_xact	Подкаталог, содержащий данные о состоянии транзакции
postgresql.auto.conf	Файл, используемый для хранения параметров конфигурации, которые устанавливаются при помощи ALTER SYSTEM
postmaster.opts	Файл, содержащий параметры командной строки, с которыми сервер был запущен в последний раз
postmaster.pid	Файл блокировки, содержащий идентификатор (ID) текущего управляющего процесса (PID), путь к каталогу данных кластера, время запуска управляющего процесса, номер порта, путь к каталогу Unix-сокета (может быть пустым), первый корректный адрес прослушивания (listen_address) (IP-адрес или *, либо пустое значение в случае отсутствия прослушивания по TCP), и ID сегмента разделяемой памяти (этот файл отсутствует после остановки сервера).

Кластер баз данных

ЦИФРОВАЯ АКАДЕМИЯ

Табличные пространства

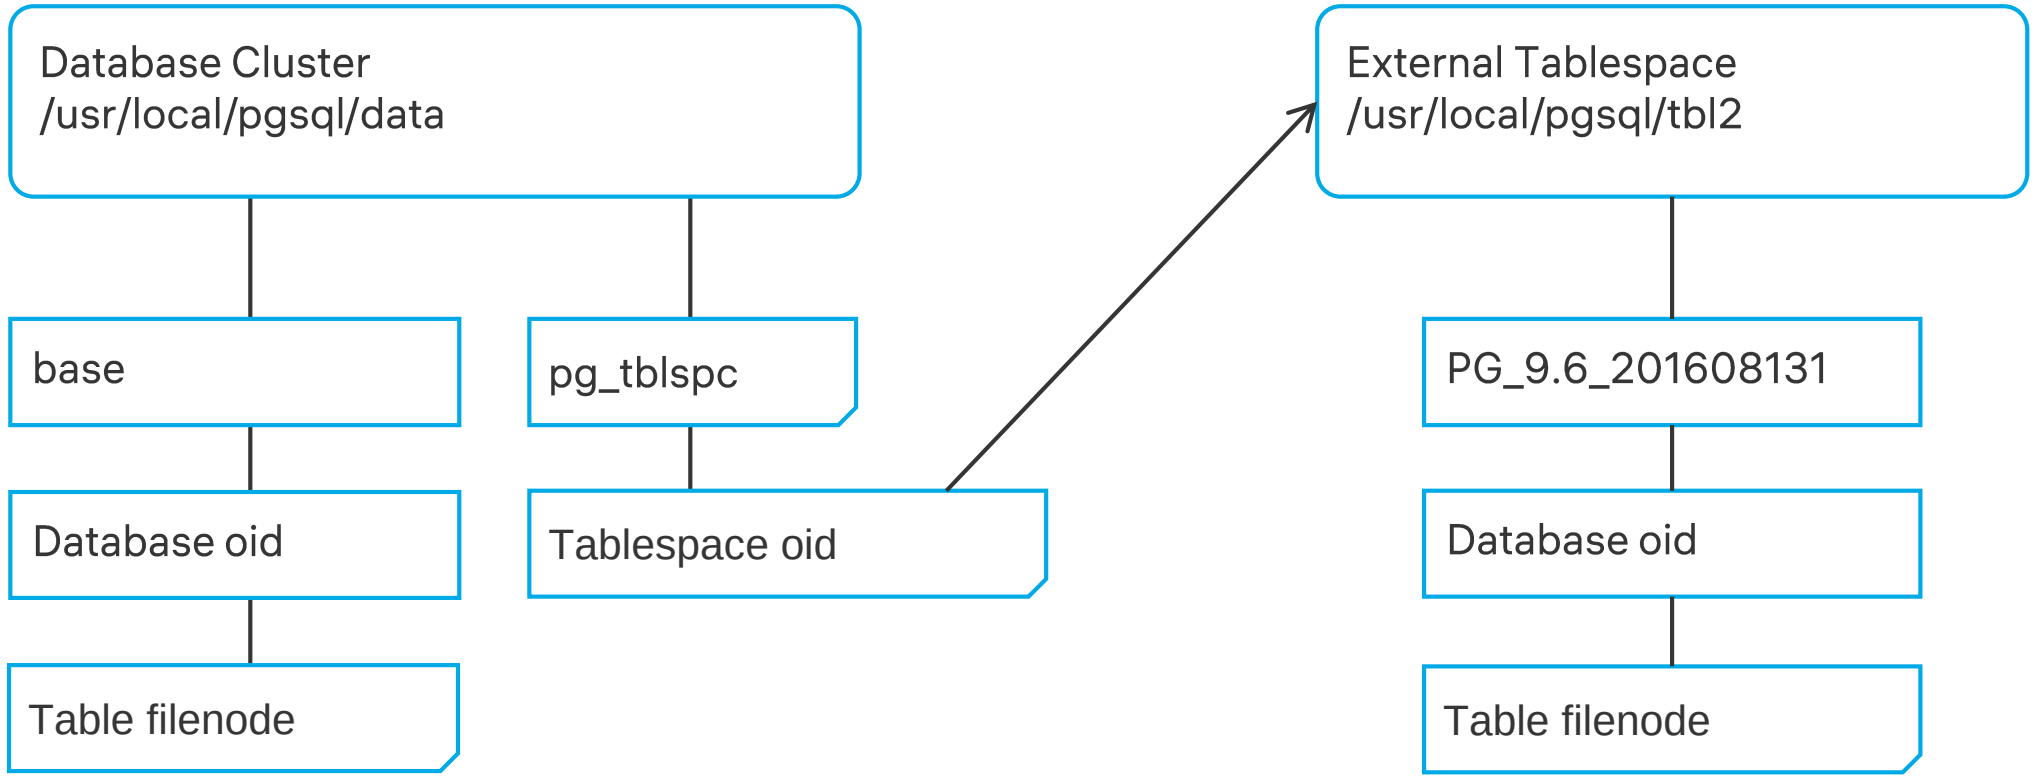

Демонстрация

ЦИФРОВАЯ АКАДЕМИЯ

- запуск
- настройка параметров
- запуск тестовой нагрузки
- аварийное завершение
- просмотр журнала
- просмотр процессов
- запрет сетевых подключений через pg_hba.conf

ЦИФРОВАЯ АКАДЕМИЯ

№2

Транзакции

Транзакции

ЦИФРОВАЯ АКАДЕМИЯ

Транзакции — это фундаментальное понятие во всех СУБД. Суть транзакции в том, что она объединяет последовательность действий в одну операцию «всё или ничего».

Промежуточные состояния внутри последовательности не видны другим транзакциям, и если что-то помешает успешно завершить транзакцию, ни один из результатов этих действий не сохранится в базе данных

- txid_current() (до версии 13)
- pg_current_xact_id()
- pg_current_xact_id_if_assigned()
- txid_status(1234)
- select xmin,xmax,...
- pg_last_committed_xact()

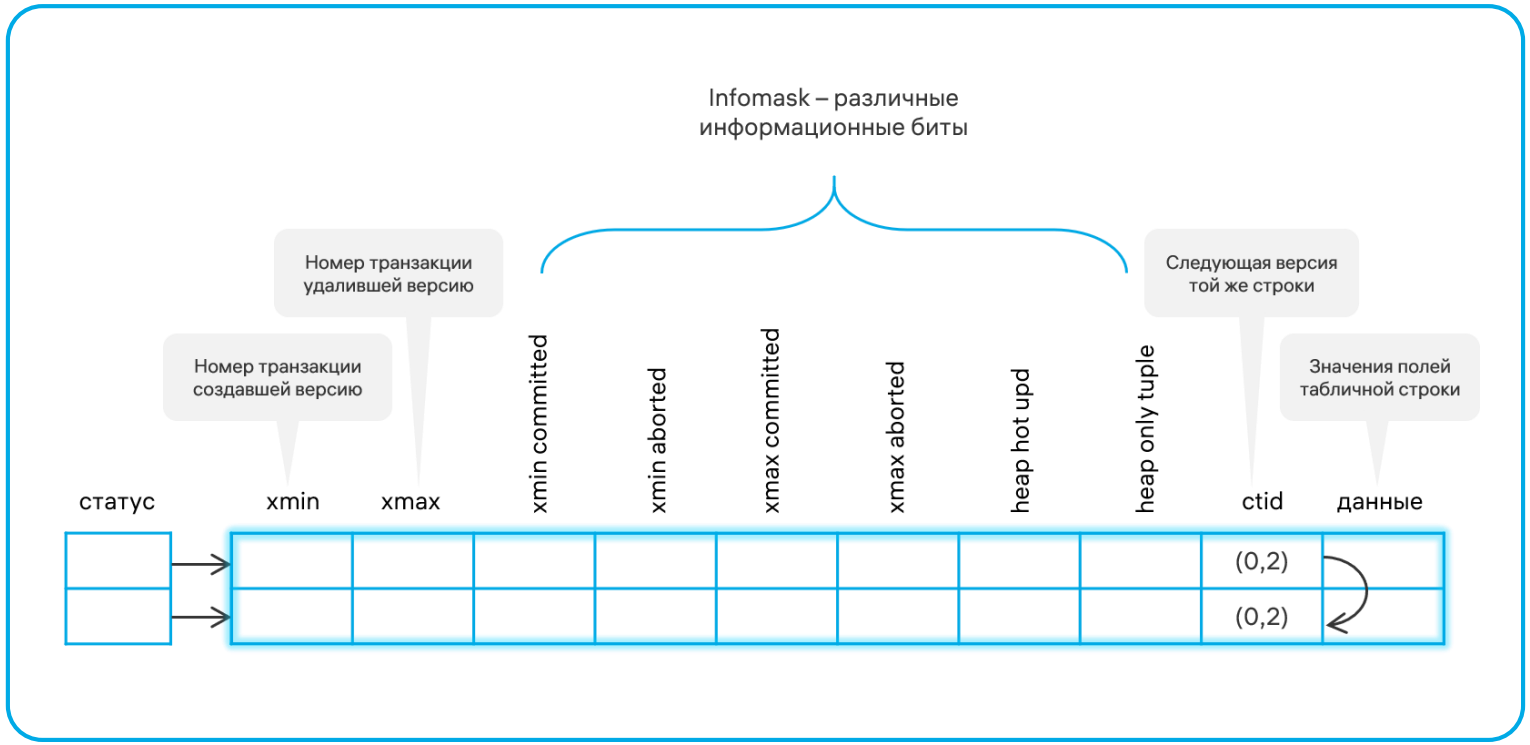

Свойство транзакции

ЦИФРОВАЯ АКАДЕМИЯ

ACID

- Атомарность (Atomicity) — все или ничего
- Согласованность (Consistency) — ограничения целостности и пользовательские ограничения
- Изоляция (Isolation) — влияние параллельных процессов
- Долговечность (Durability) — сохранность данных даже после сбоя

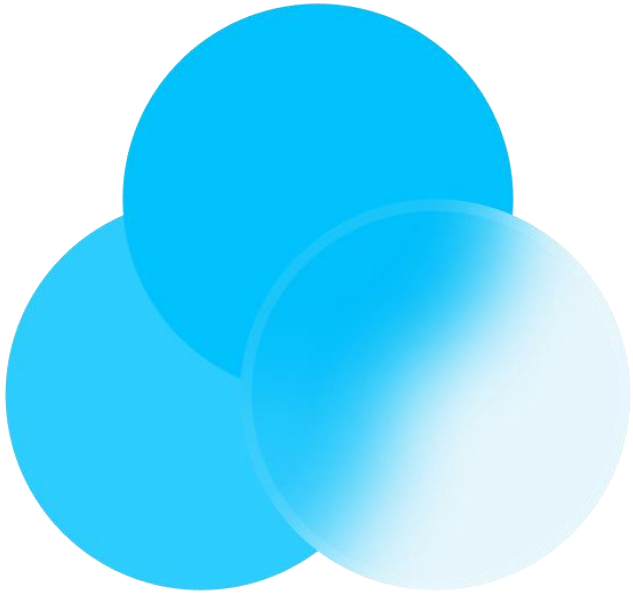

Интерактив

ЦИФРОВАЯ АКАДЕМИЯ

- Чем отличаются транзакционные базы данных от нетранзакционных?
- Какие примеры Вы можете привести?

Взаимодействие клиент-сервер

ЦИФРОВАЯ АКАДЕМИЯ

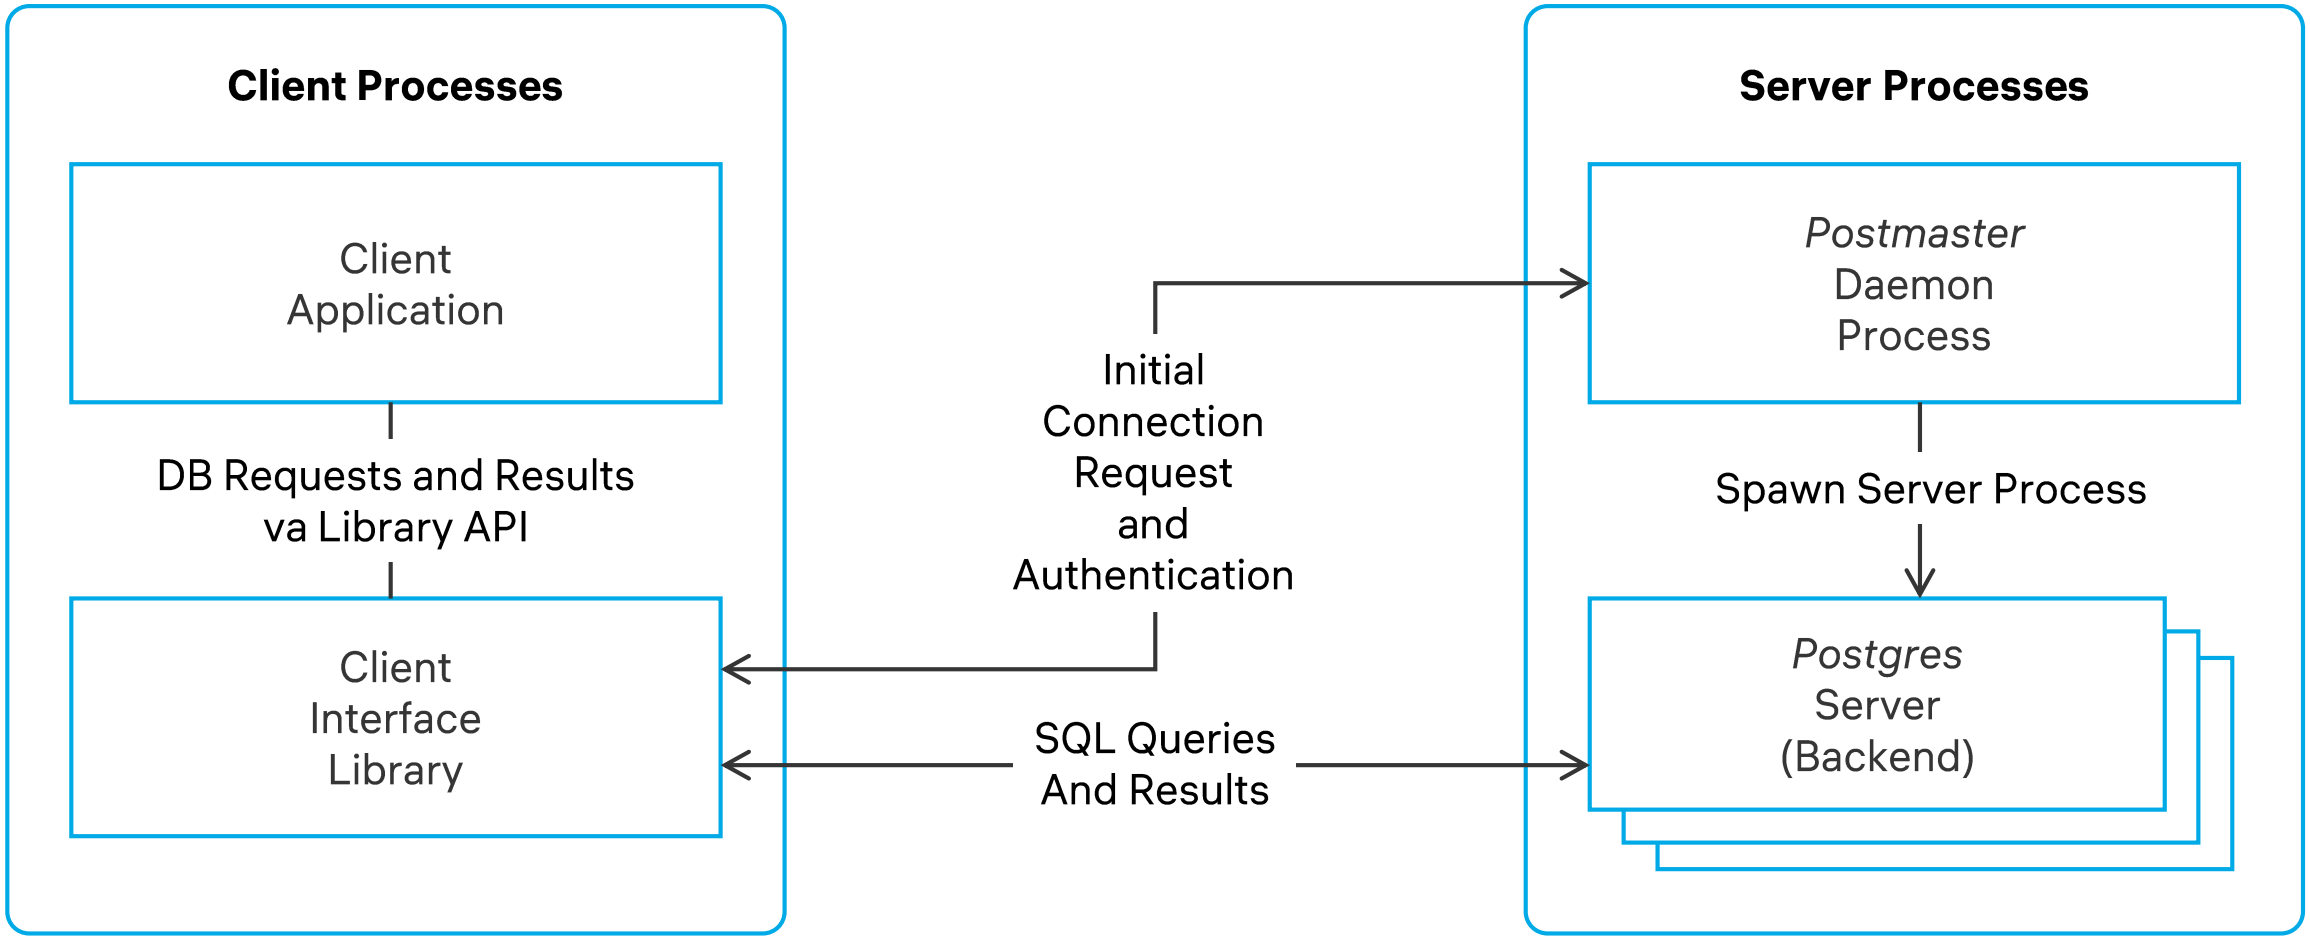

Взаимодействие клиент-сервер

ЦИФРОВАЯ АКАДЕМИЯ

Выделенный серверный процесс

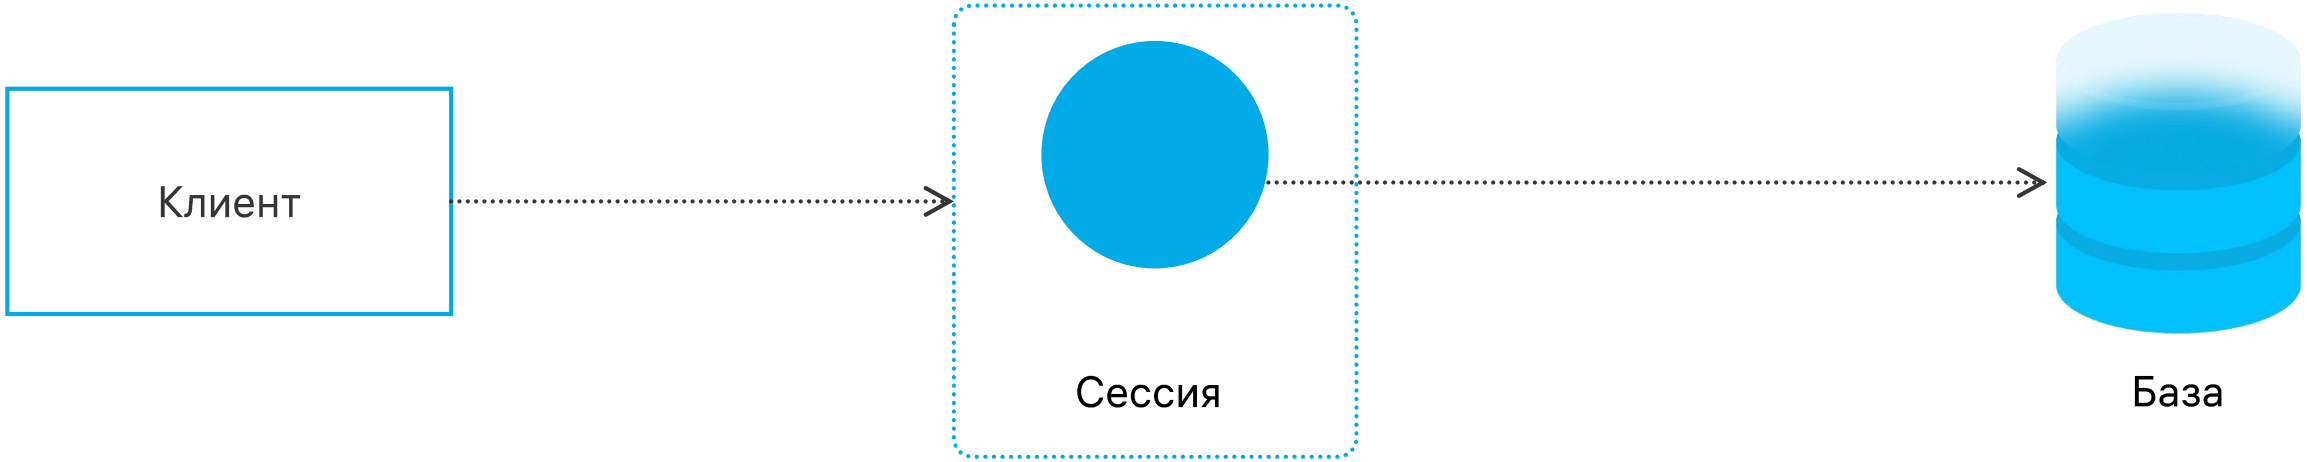

Разделяемый серверный процесс / pgbouncer

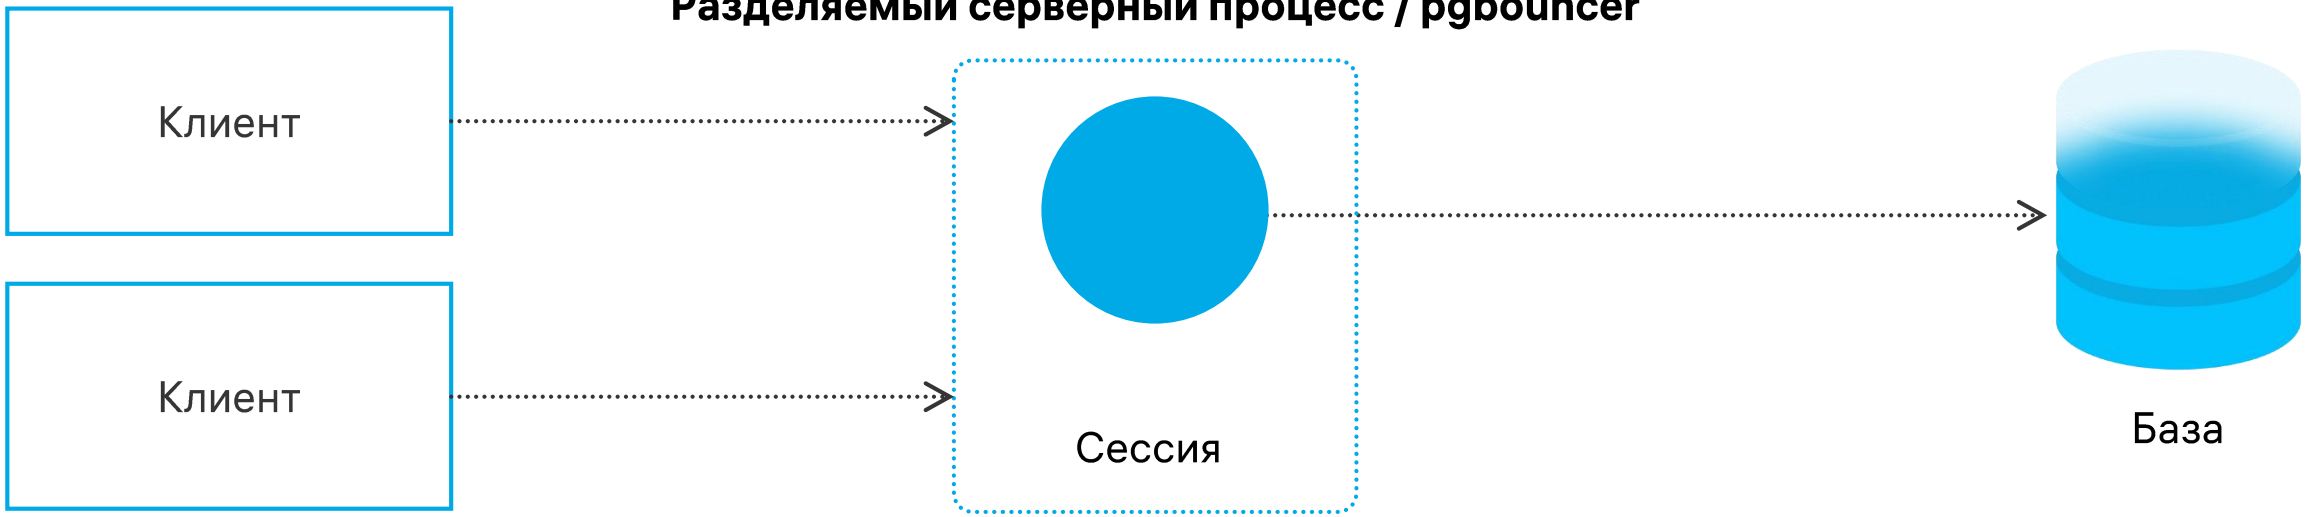

Уровни изоляции

ЦИФРОВАЯ АКАДЕМИЯ

- **Read uncommitted** — не поддерживается PostgreSQL
  - позволяет читать не зафиксированные данные
- **Read committed** — используется по умолчанию
  - снимок строится на момент начала оператора
  - одинаковые запросы могут каждый раз получать разные данные
- **Repeatable read**
  - снимок строится на момент начала первого оператора транзакции
  - транзакция может завершиться ошибкой сериализации
- **Serializable**
  - полная изоляция, но дополнительные накладные расходы
  - транзакция может завершиться ошибкой сериализации

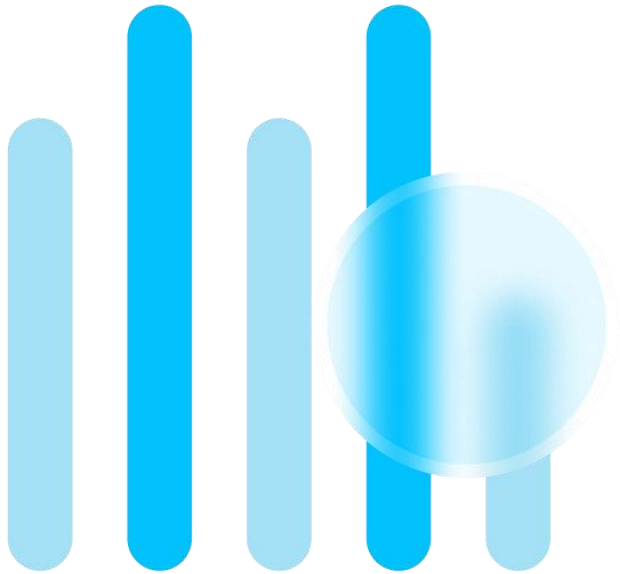

Уровни изоляции в PostgreSQL

ЦИФРОВАЯ АКАДЕМИЯ

Уровень изоляции	«Грязное» чтение	Неповторяемое чтение	Фантомное чтение	Аномалия сериализации
Read uncommited (Чтение незафиксированных данных)	Допускается, но не в PG	Возможно	Возможно	Возможно
Read committed (Чтение зафиксированных данных)	Невозможно	Возможно	Возможно	Возможно
Repeatable read (Повторяемое чтение)	Невозможно	Невозможно	Допускается, но не в PG	Возможно
Serializable (Сериализуемость)	Невозможно	Невозможно	Невозможно	Невозможно

ЦИФРОВАЯ АКАДЕМИЯ

№3

Фазы выполнения запросов, оптимизатор

Фазы выполнения запросов

ЦИФРОВАЯ АКАДЕМИЯ

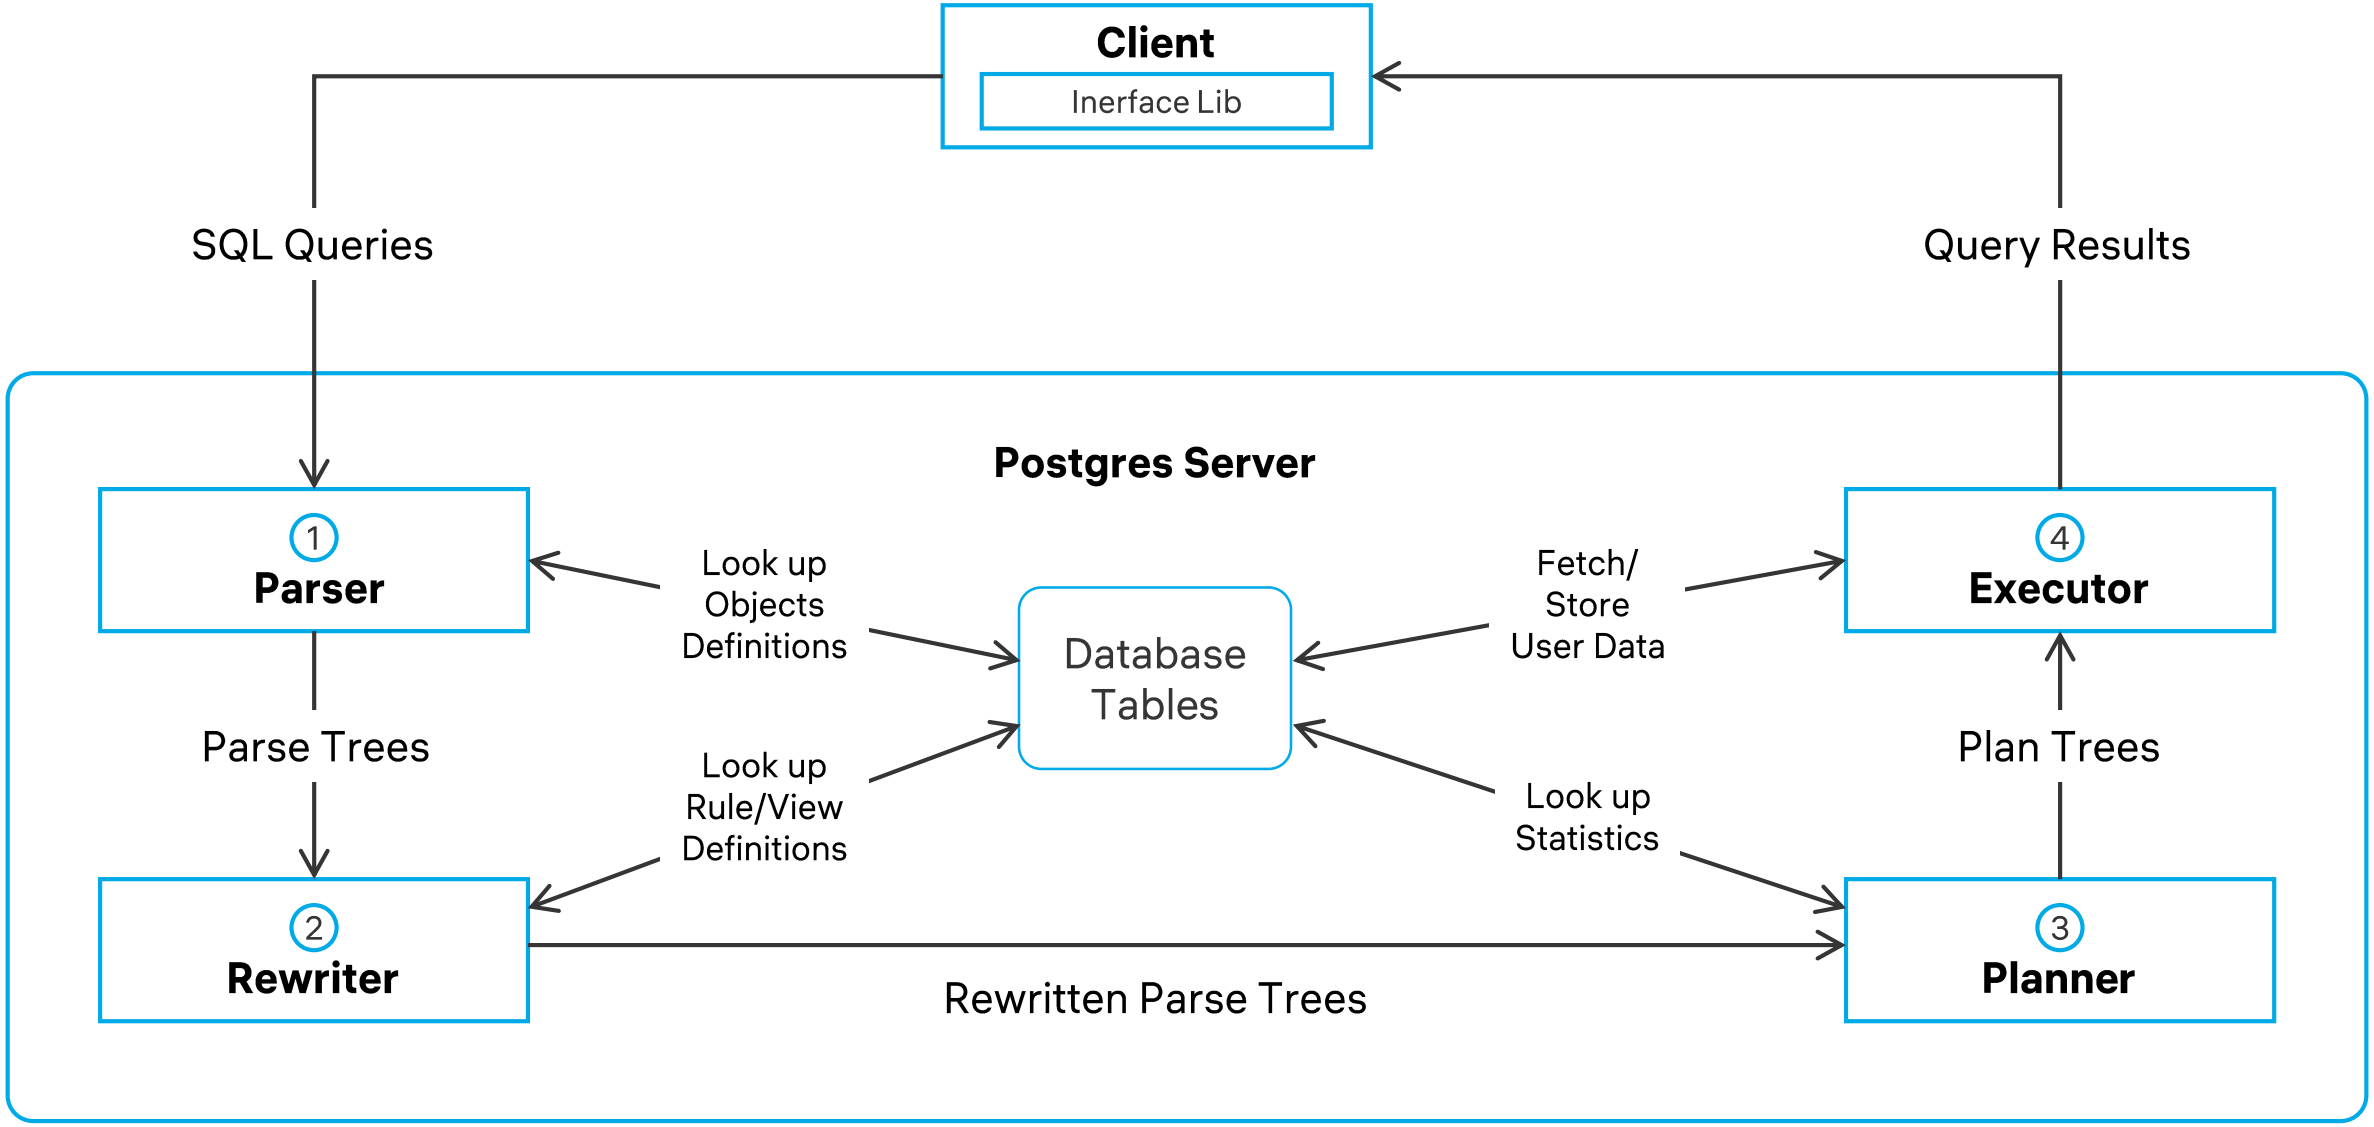

Фаза анализ (Parse)

ЦИФРОВАЯ АКАДЕМИЯ

+ Синтаксис
+ Семантика

SELECT * FROM tab1, tab2 WHERE tab1.a = tab2.f

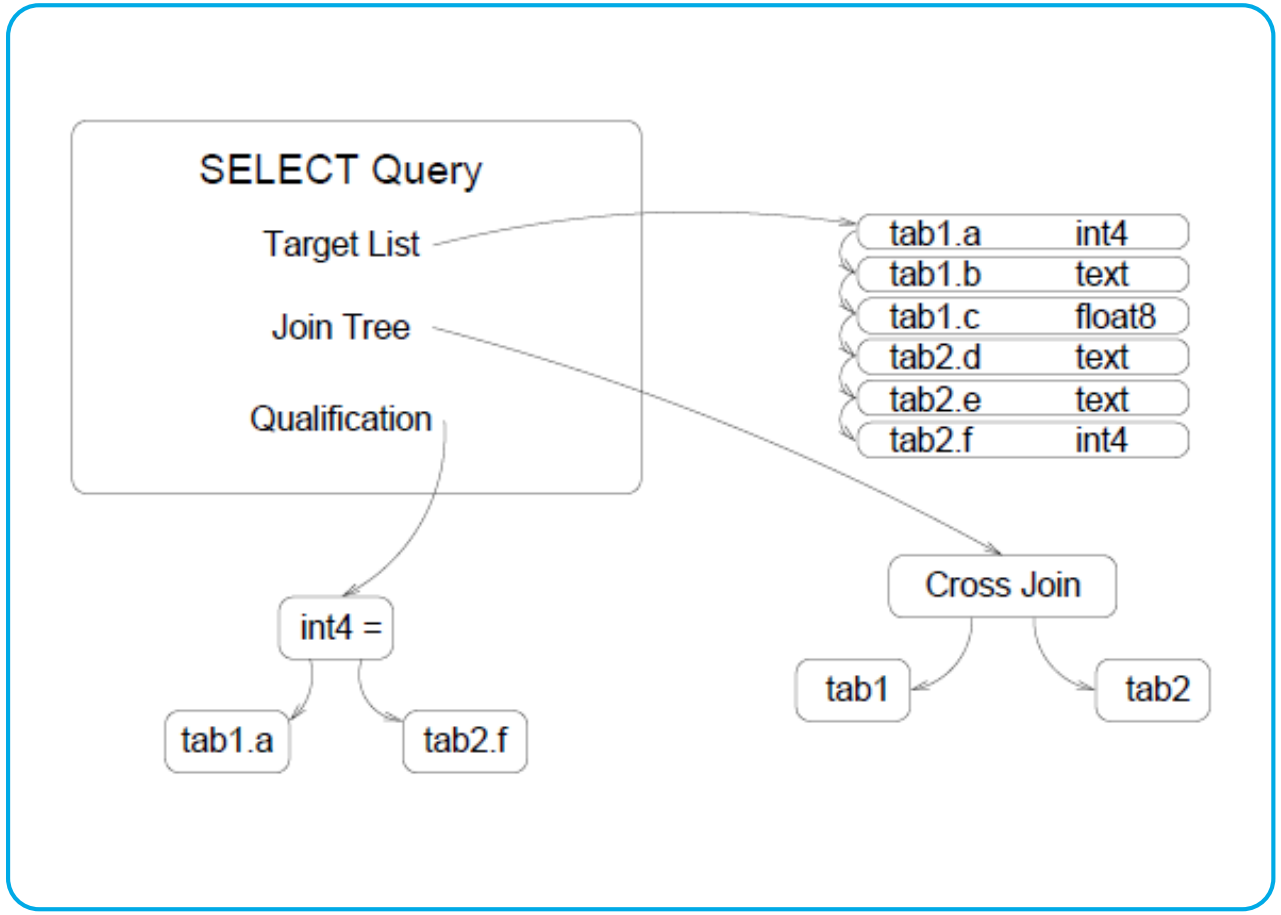

Фаза переписывания (Rewrite)

ЦИФРОВАЯ АКАДЕМИЯ

- Views
- Rules

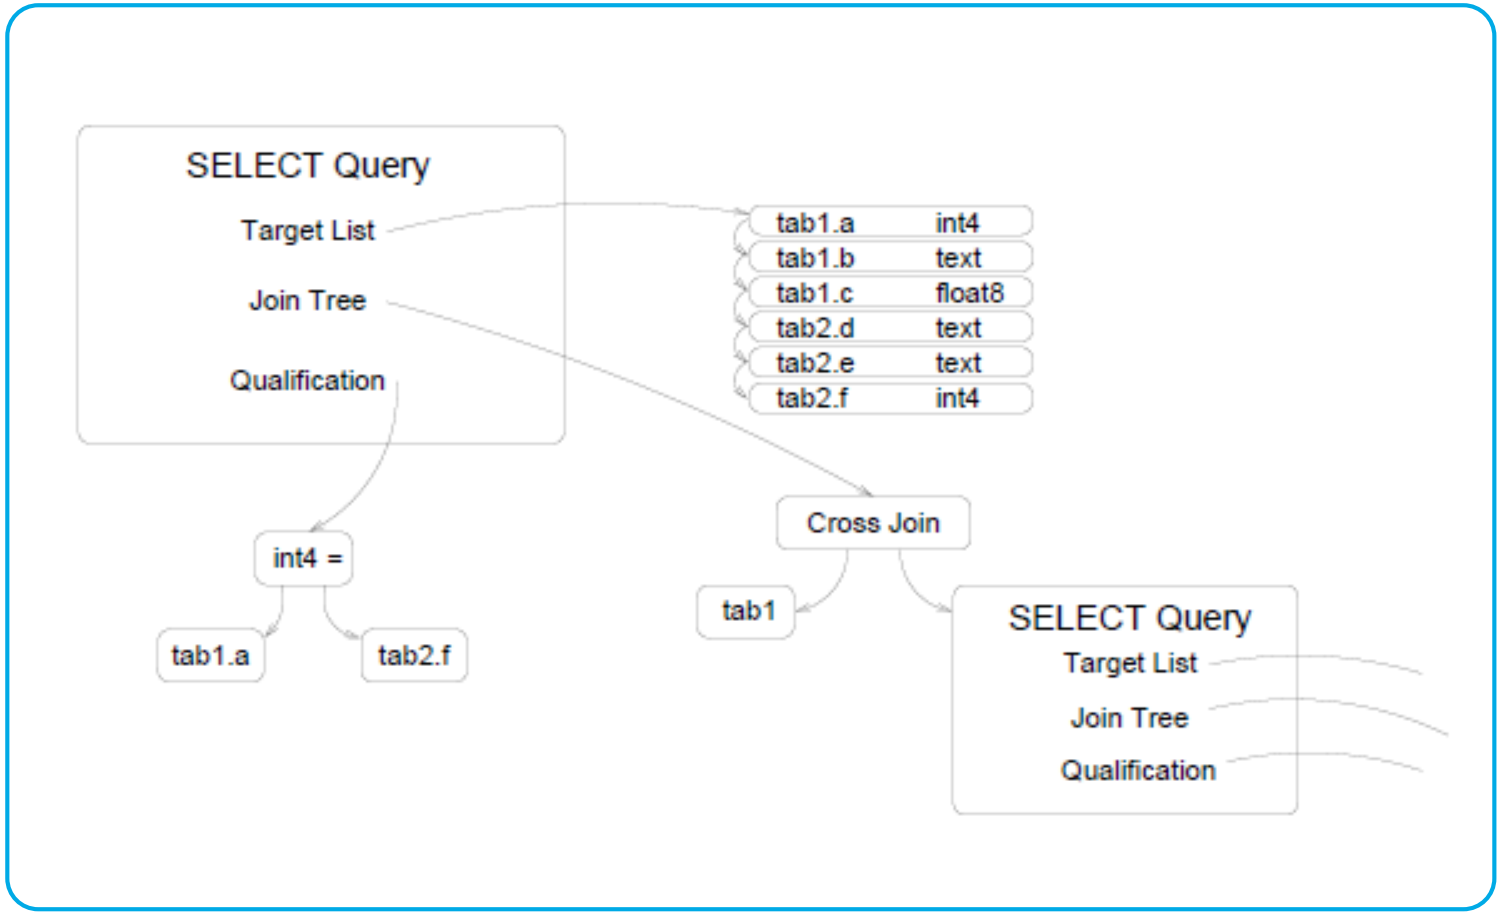

Фаза планирования (Planner)

ЦИФРОВАЯ АКАДЕМИЯ

- SQL — декларативный язык, и один запрос можно выполнить разными способами
- Планировщик (он же оптимизатор) перебирает различные способы выполнения и оценивает их
- Оценка дается на основе некоторой математической модели исходя из информации об обрабатываемых данных (статистики)
- Тот способ выполнения, для которого прогнозируется минимальная стоимость, представляется в виде дерева плана

Фаза выполнения (Executor)

ЦИФРОВАЯ АКАДЕМИЯ

SELECT DISTINCT a1, b1 FROM a, b WHERE a2 = b2 AND a3 = 42

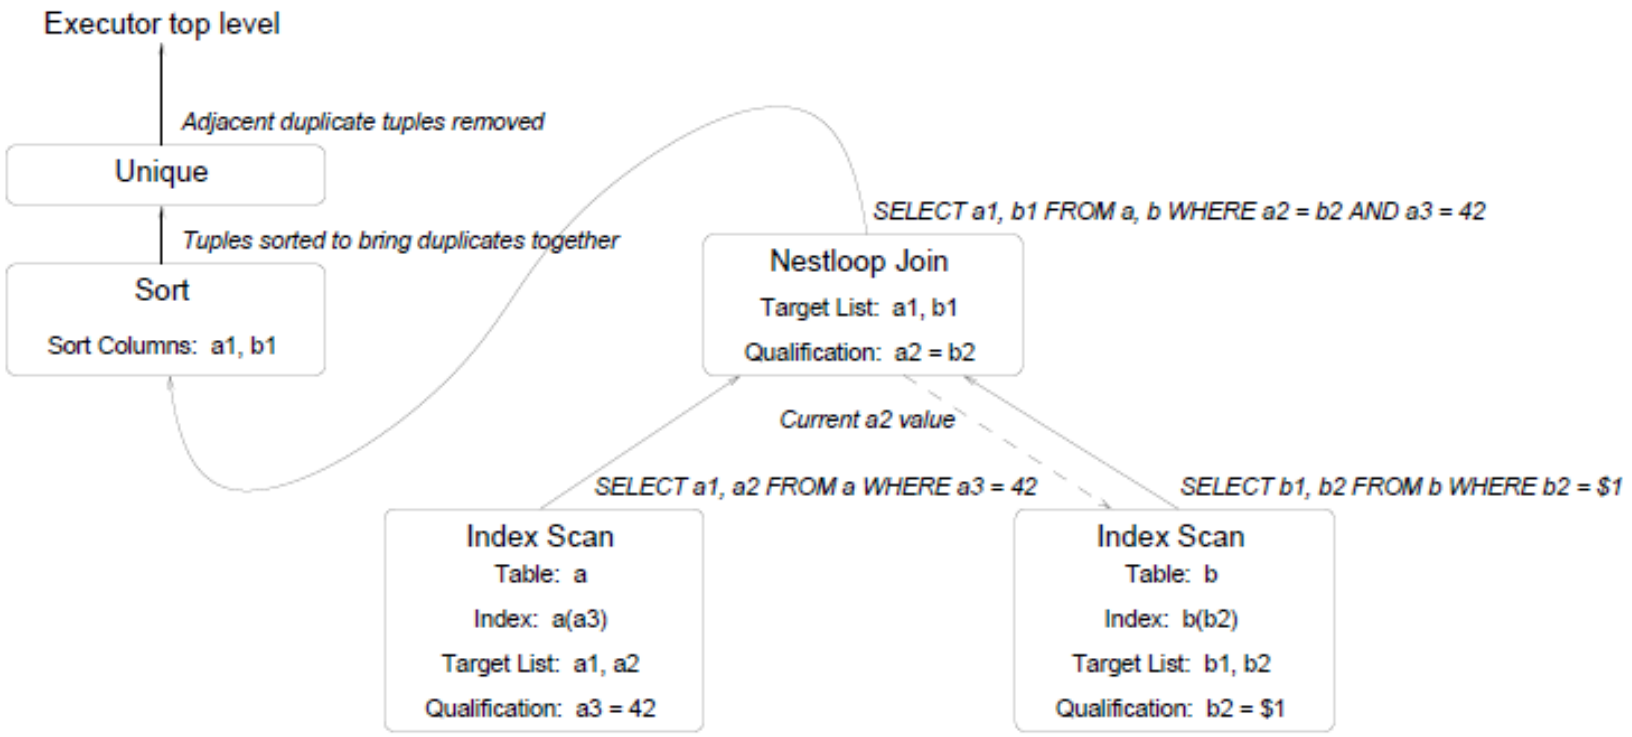

Фазы выполнения. Простой протокол

ЦИФРОВАЯ АКАДЕМИЯ

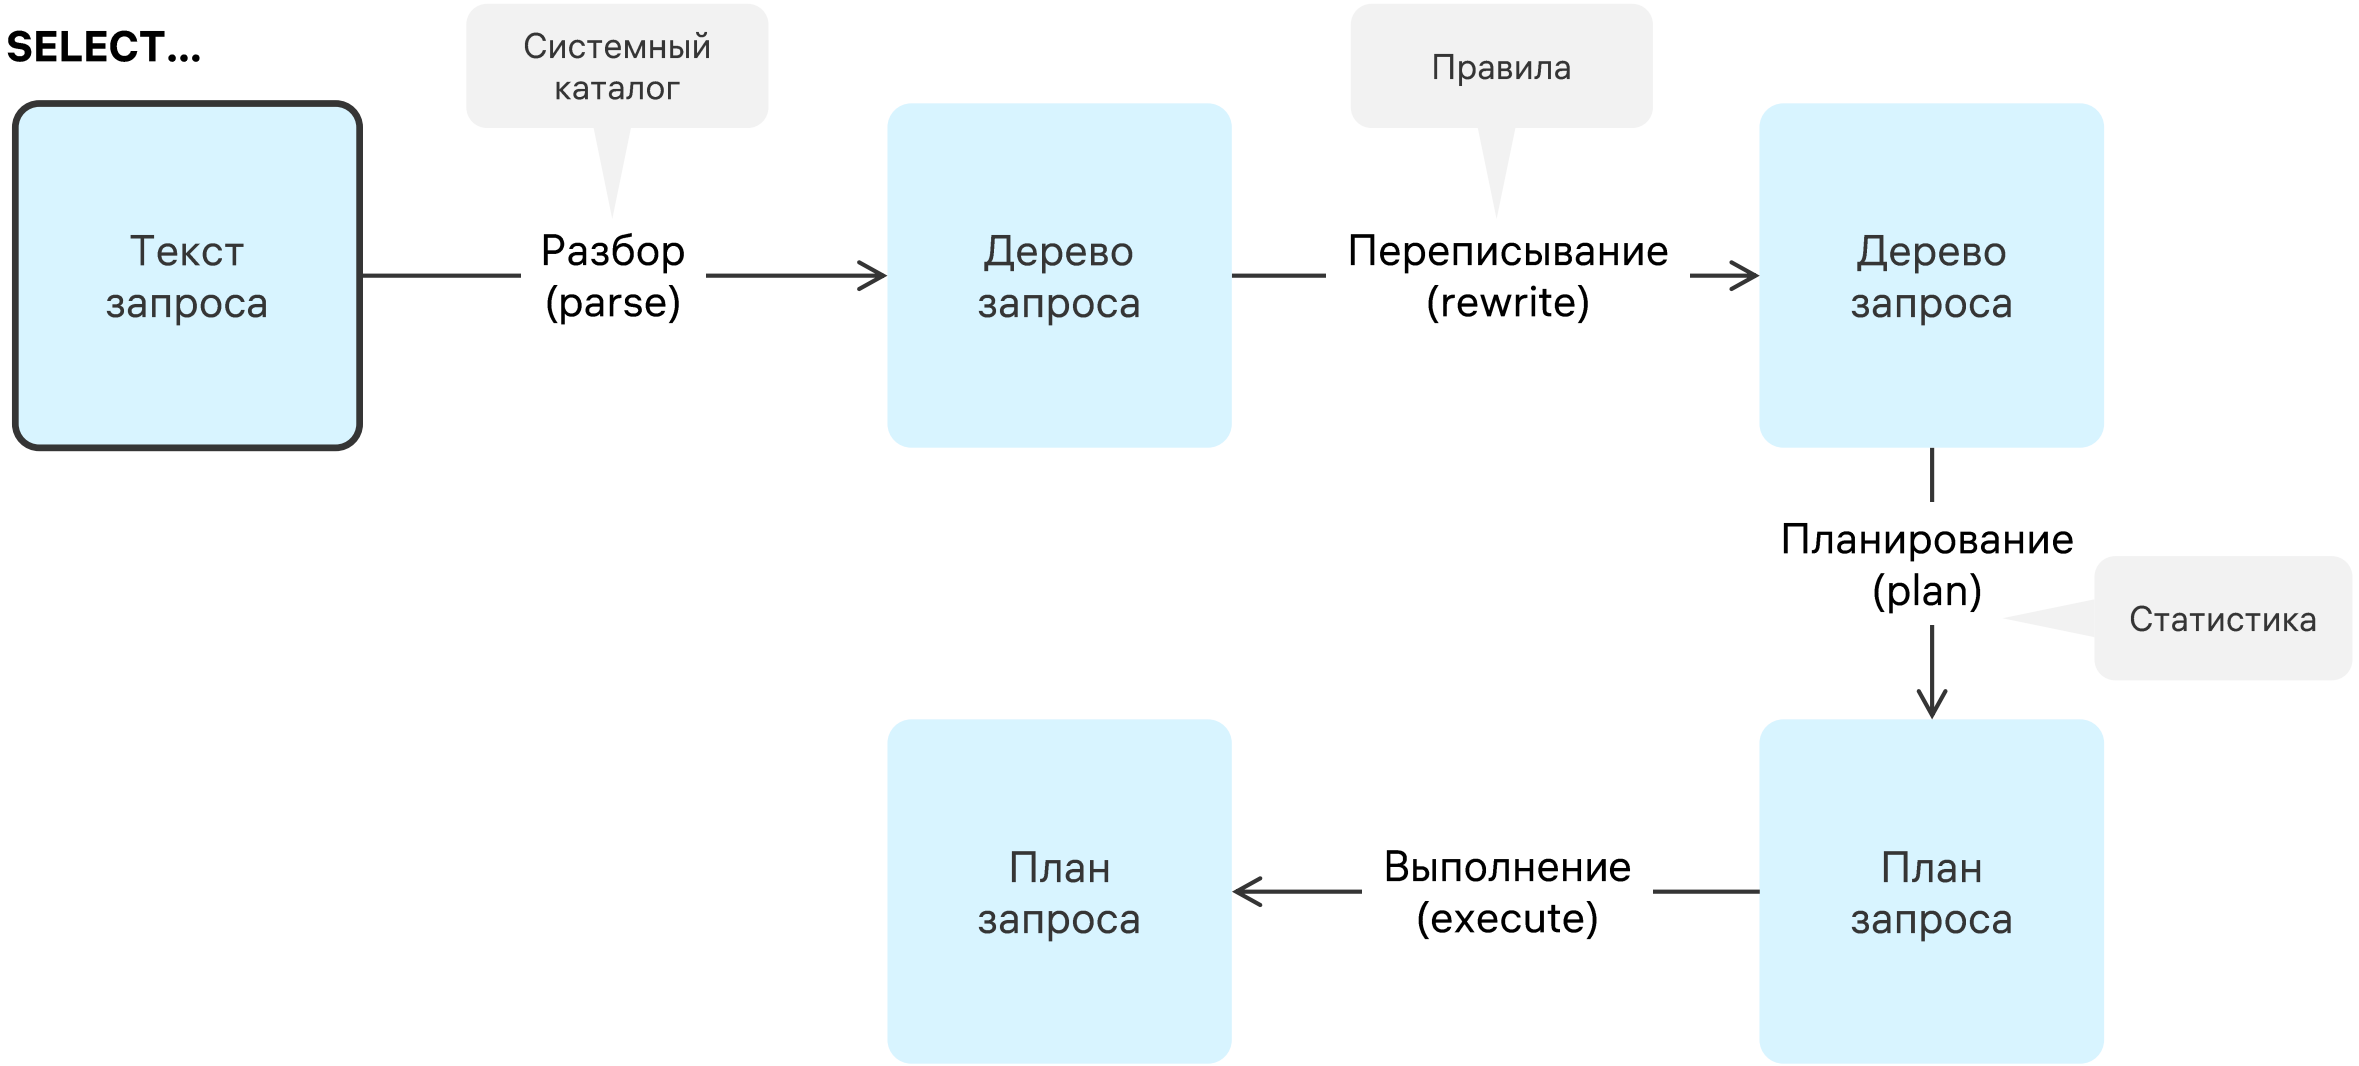

Фазы выполнения. Подготовленные операторы

ЦИФРОВАЯ АКАДЕМИЯ

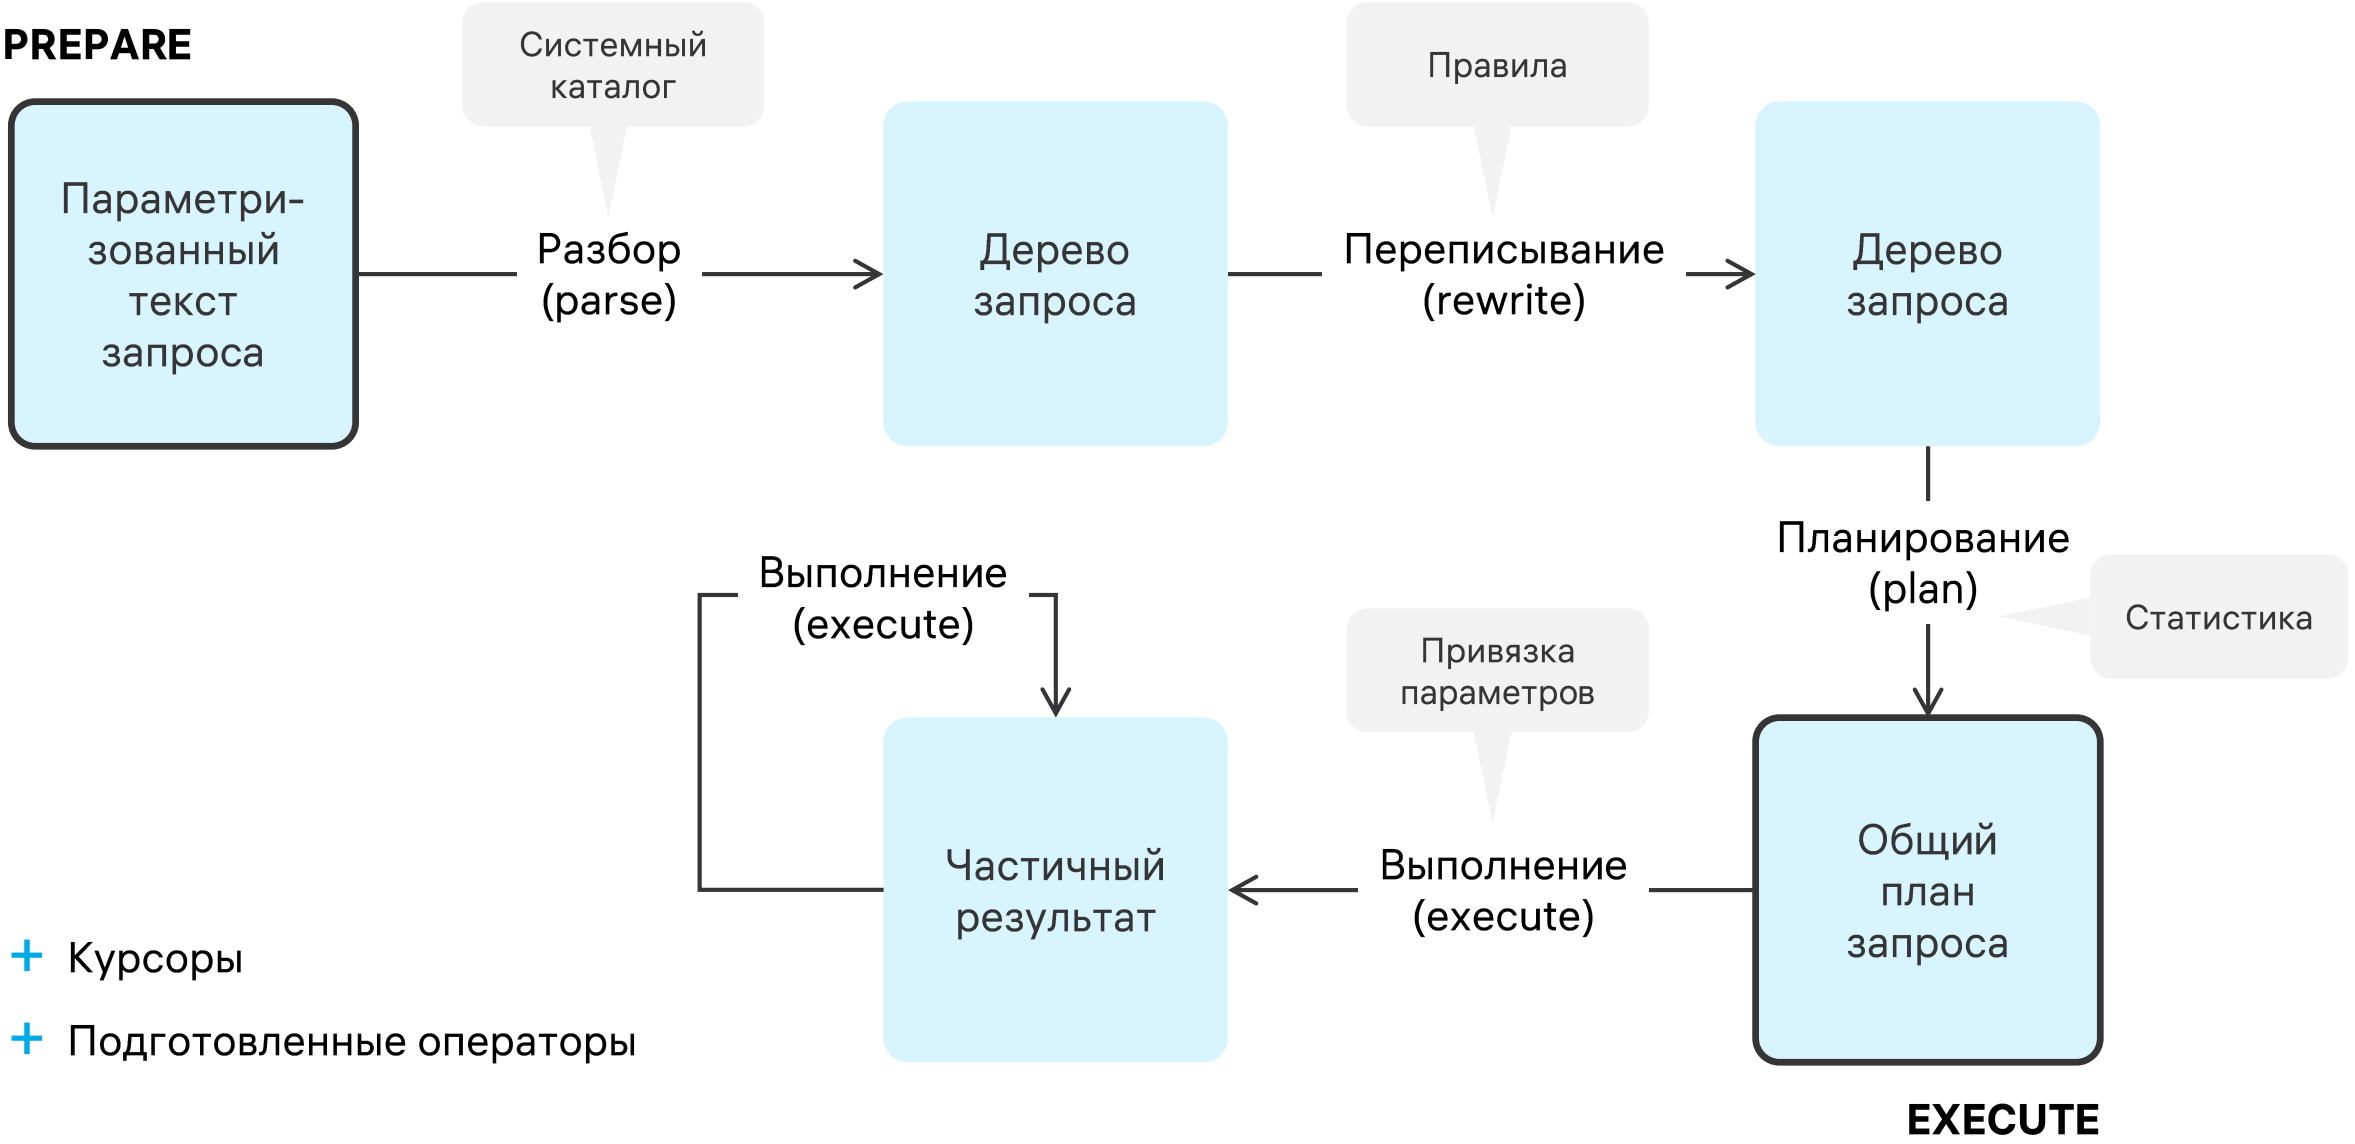

+ Курсоры
+ Подготовленные операторы

Интерактив

ЦИФРОВАЯ АКАДЕМИЯ

+ Есть ли смысл от использования подготовленных операторов для аналитических приложений?

Демонстрация

ЦИФРОВАЯ АКАДЕМИЯ

- Статистика по фазам выполнения запросов
- Вывод планов выполнения в журнал

ЦИФРОВАЯ АКАДЕМИЯ

№4

Структура страницы

Структура страницы

ЦИФРОВАЯ АКАДЕМИЯ

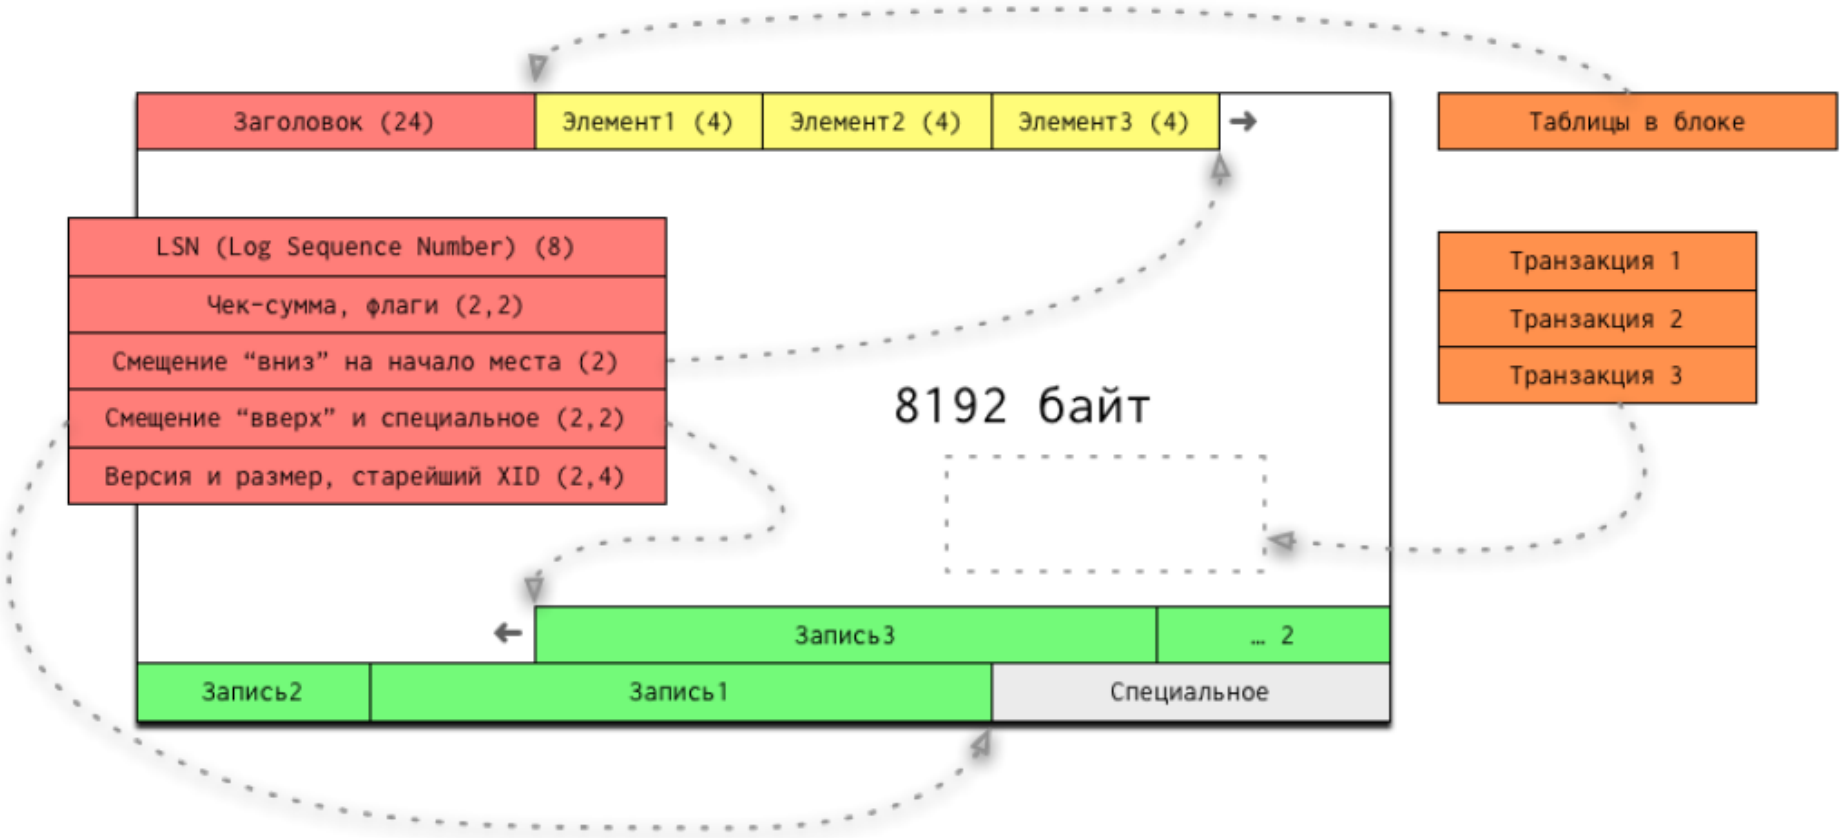

Интерактив

ЦИФРОВАЯ АКАДЕМИЯ

- В чем отличие страницы таблица от страницы индекса?
- Есть ли возможность задать бОльший размер страницы?

Демонстрация

ЦИФРОВАЯ АКАДЕМИЯ

- Доступ к странице через разширение pageinspect
- Просмотр слоев данных в файловой системе

ЦИФРОВАЯ АКАДЕМИЯ

№5

Многоверсионность (MVCC)

Многоверсионность (MVCC)

ЦИФРОВАЯ АКАДЕМИЯ

- Наличие нескольких версий одной и той же строки
  - версии различаются временем действия
  - время = номер транзакции (номера выдаются по возрастанию)

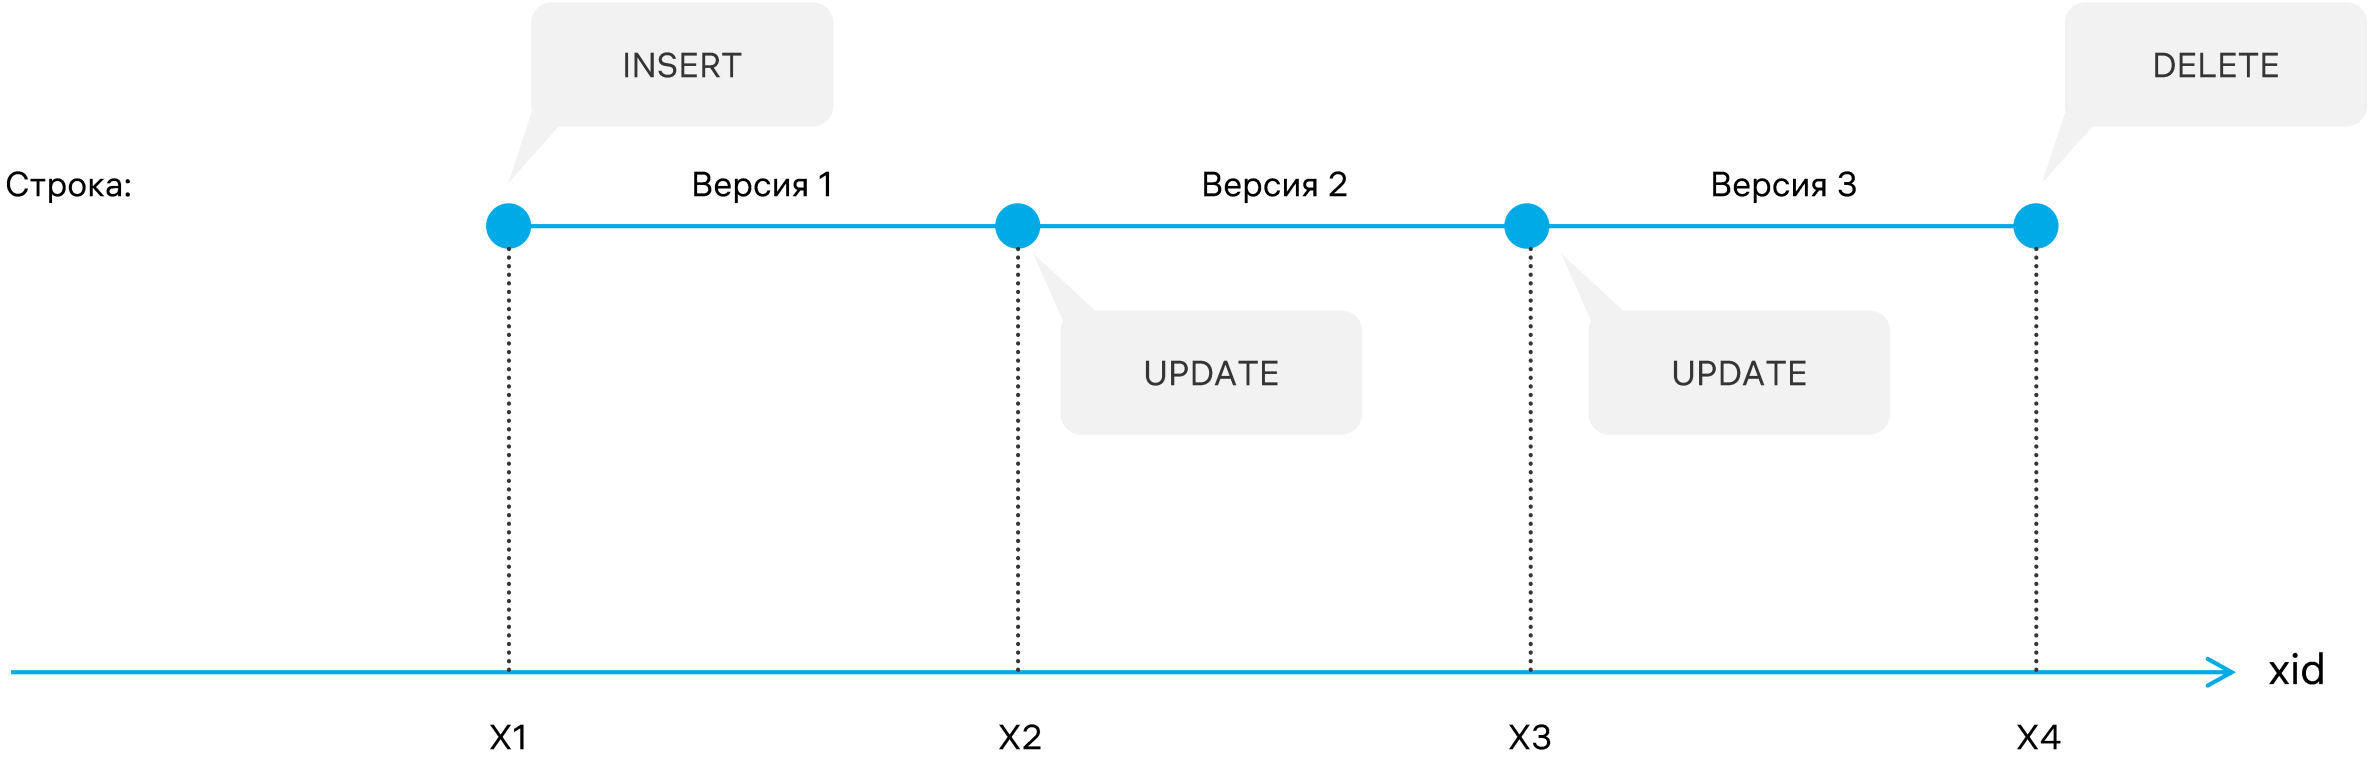

Многоверсионность (MVCC)

ЦИФРОВАЯ АКАДЕМИЯ

- Файлы таблицы хранят версии строк (tuple), а не логические строки
- Индексы индексируют версии строк, а не логические строки
- При обновлении индексированного поля таблицы все индексы получают новую строку
- Необходима очистка от «мёртвых» версий строк

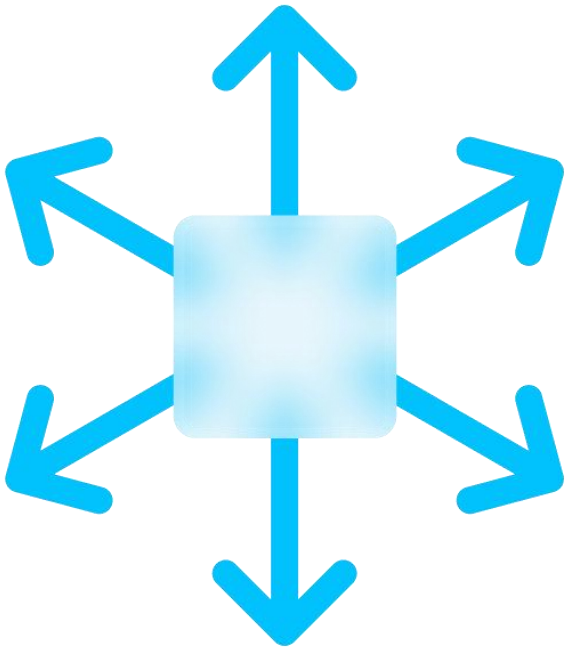

Файлы таблицы

ЦИФРОВАЯ АКАДЕМИЯ

Основной

+ собственно данные

Карта видимости (vm)

+ отмечает страницы, на которых все версии строк видны во всех снимках
+ используется для оптимизации работы процесса очистки
+ и ускорения индексного доступа
+ существует только для таблиц

Карта свободного пространства (fsm)

+ отмечает свободное пространство в страницах после очистки
+ используется при вставке новых версий строк

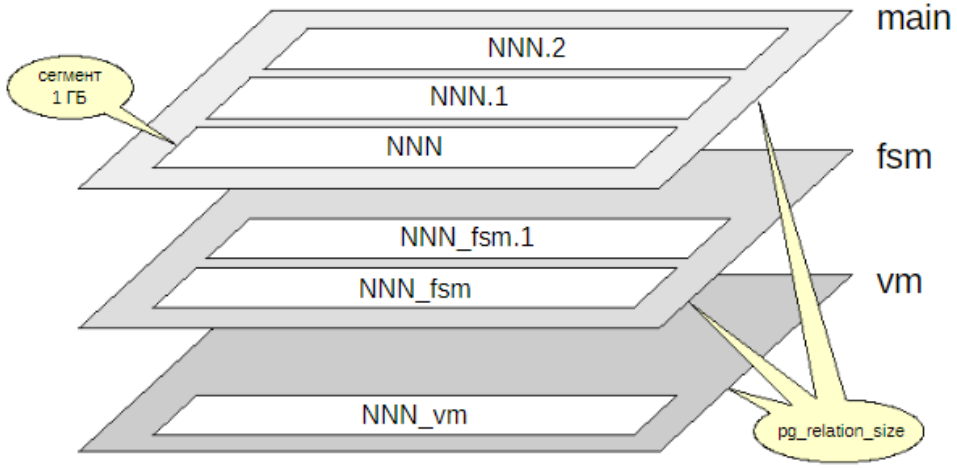

Карты VM и FSM

ЦИФРОВАЯ АКАДЕМИЯ

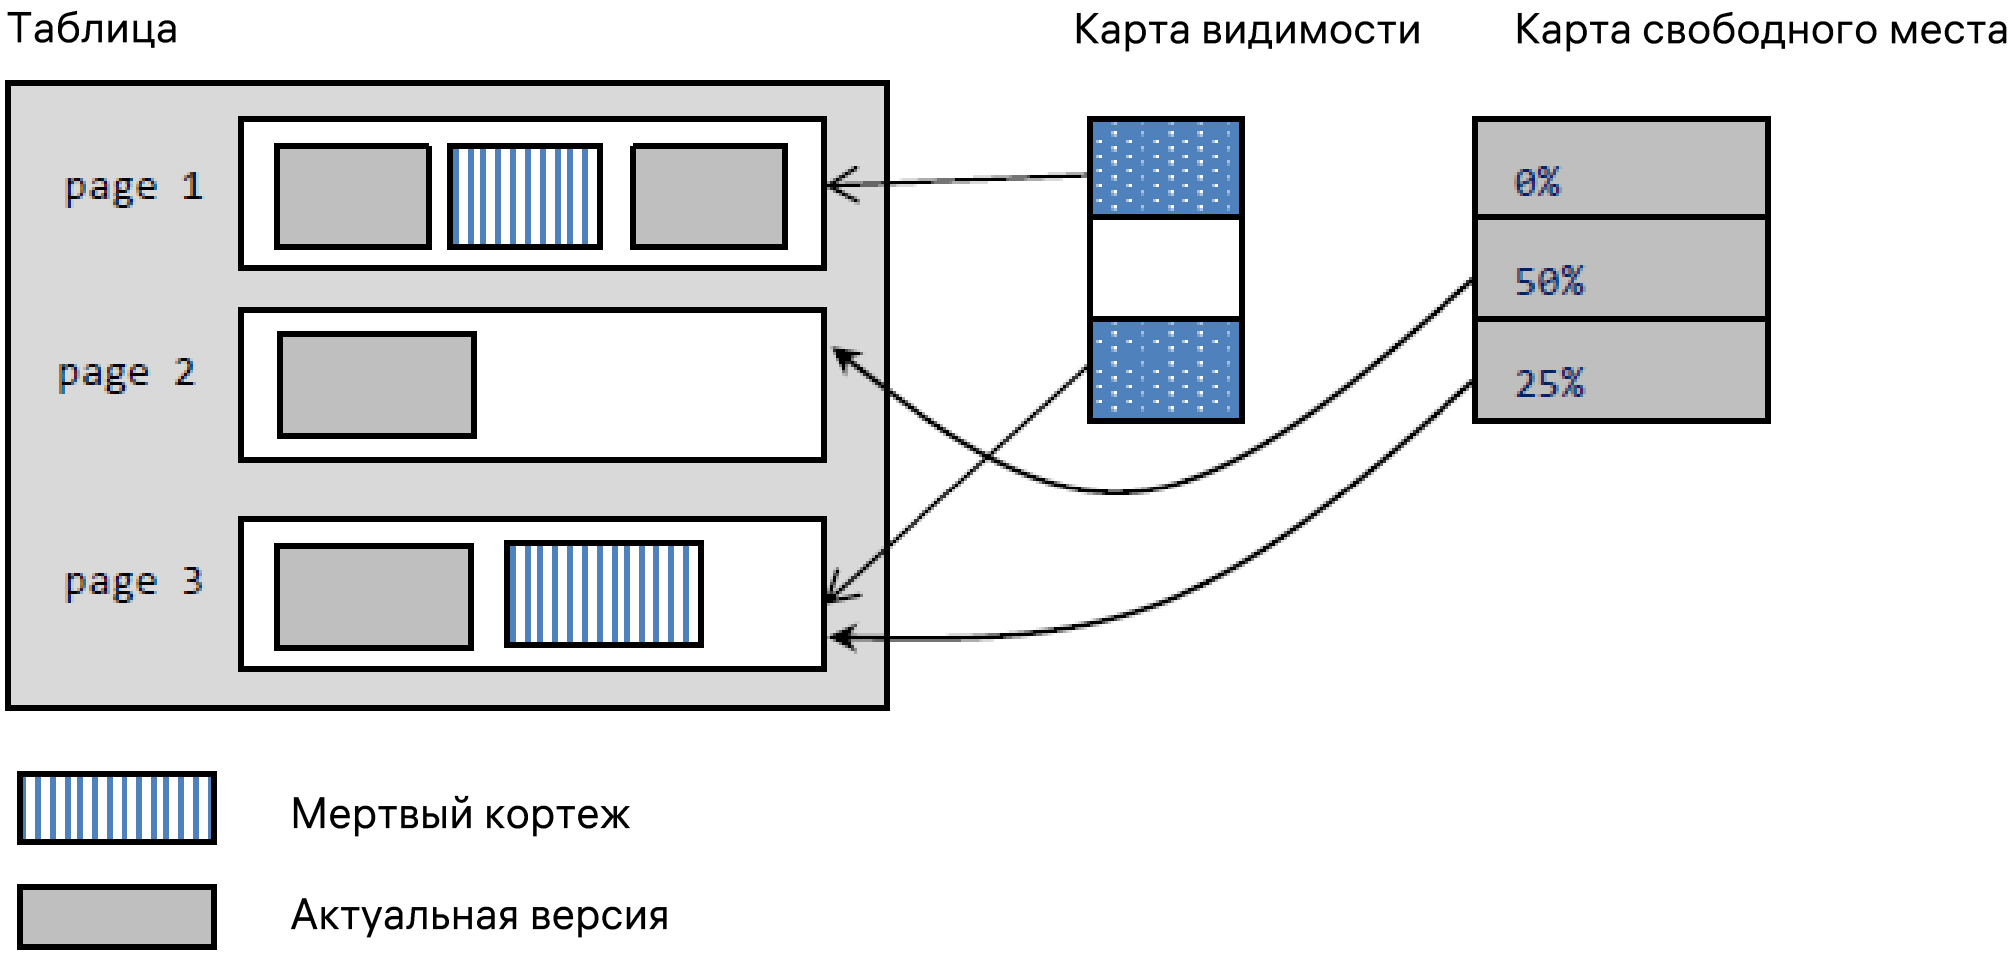

Интерактив

ЦИФРОВАЯ АКАДЕМИЯ

- Как качественно изменится размер таблицы, созданной в настройка по умолчанию, при обновлении 100% строк таблицы?
- Есть ли карта видимости для индексов?
- В каком методе доступа используется карта видимости?

№6

Задача очистки

Задача очистки

ЦИФРОВАЯ АКАДЕМИЯ

Для исправления проблем, возникающих из-за многоверсионности (MVCC), autovacuum выполняет следующие задачи:

- Очистка «мёртвых версий строк», оставленных операциями UPDATE и DELETE, MERGE
- Обновление карты свободного места (free space map), отслеживающей свободное место в блоках таблиц
- Обновление карты видимости (visibility map), которая требуется для (index only scan) исключительно индексного сканирования
- «заморозка» строк таблиц, для того чтобы счетчик транзакций мог безопасно зацикливаться (wrap around)
- Планировать запуск analyze, чтобы поддерживать статистики таблиц в актуальном состоянии

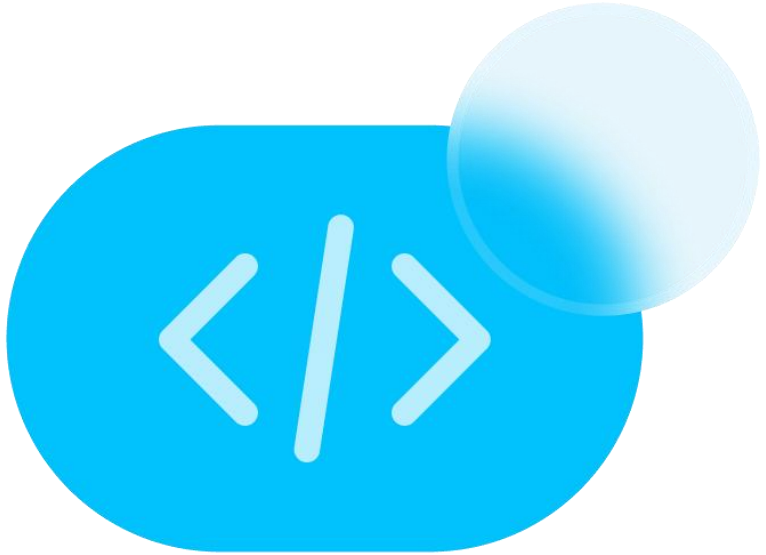

Автоочистка

ЦИФРОВАЯ АКАДЕМИЯ

Autovacuum launcher

- фоновый процесс
- реагирует на активность
- изменения данных

Autovacuum worker

- запускается
- по необходимости
- выполняет очистку

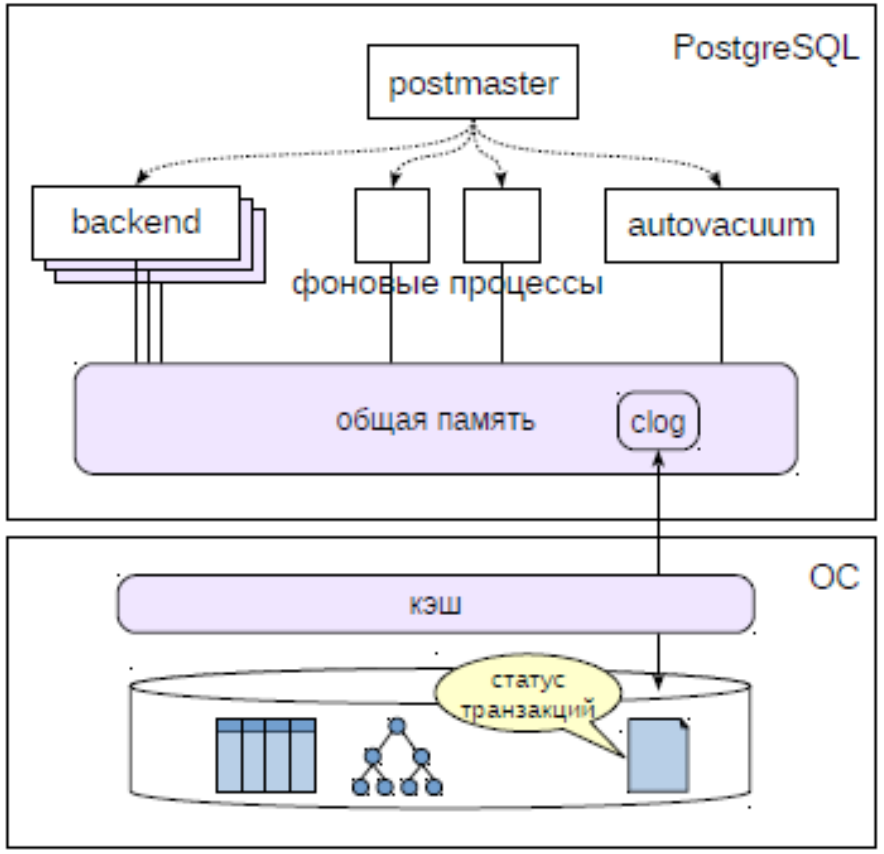

Внутристраничная очистка

ЦИФРОВАЯ АКАДЕМИЯ

Выполняется при любом обращении к странице

+ если ранее выполненное обновление не нашло места
+ для новой версии строки на этой же странице
+ если страница заполнена больше, чем на fillfactor

Действует в пределах одной табличной страницы

+ не освобождает указатели, на которые могут ссылаться индексы
+ не обновляет карту свободного пространства
+ не обновляет карту видимости

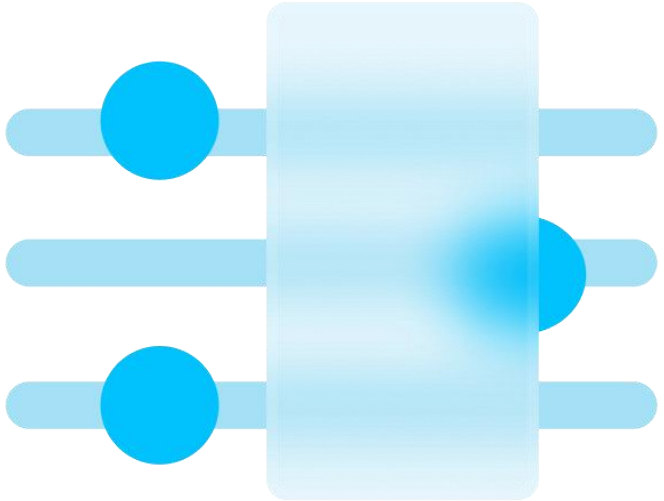

Разбухание таблиц

ЦИФРОВАЯ АКАДЕМИЯ

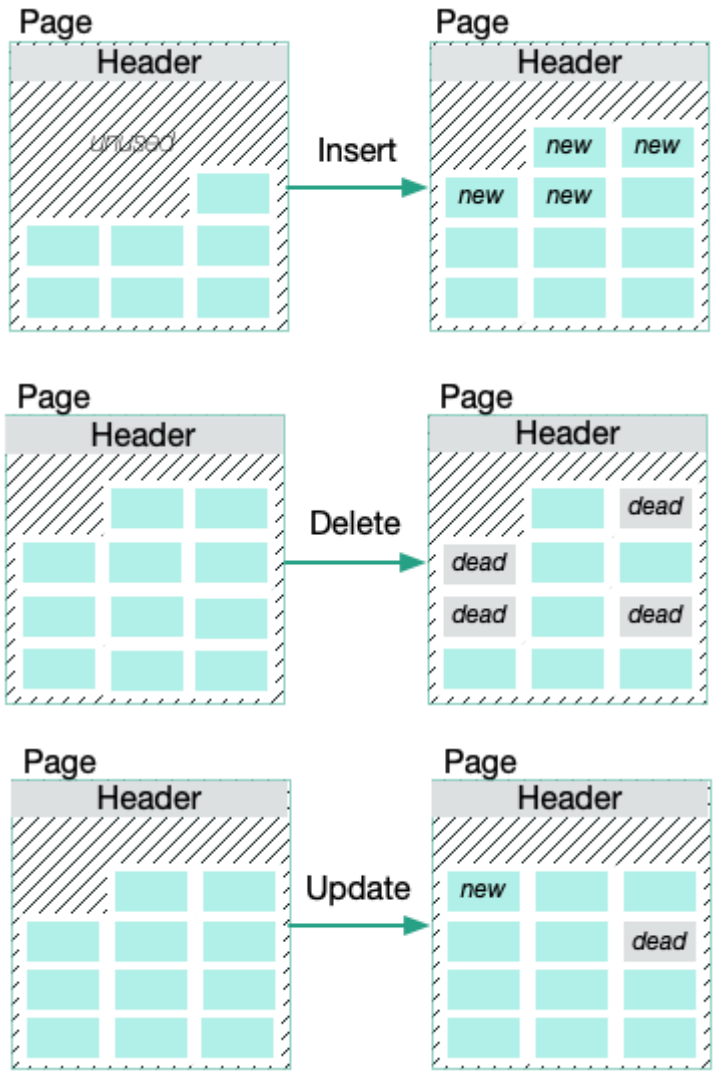

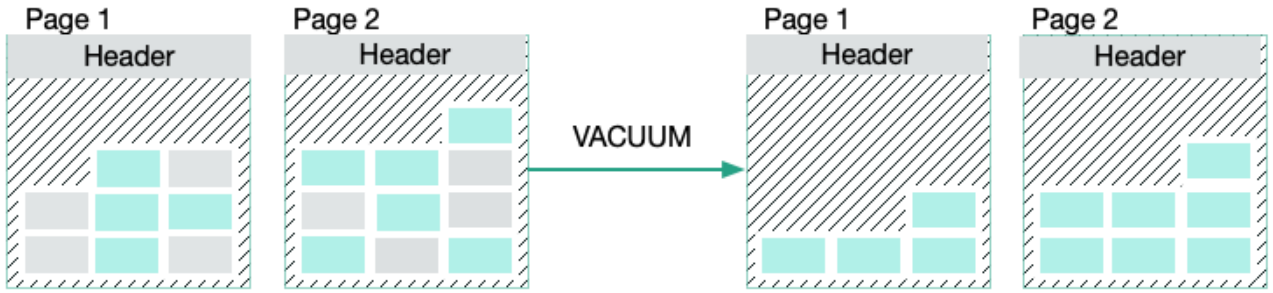

Интерактив

ЦИФРОВАЯ АКАДЕМИЯ

+ Как частно необходимо использовать vacuum ful?

Демонстрация

ЦИФРОВАЯ АКАДЕМИЯ

- Проверка очистки после аварийного завершения
- Пример разбухания таблиц и индексов

Итоги

ЦИФРОВАЯ АКАДЕМИЯ

- Экземпляр, структуры памяти, фоновые процессы
- Транзакции
- Фазы выполнения запросов, оптимизатор
- Структура страница таблицы и индекса
- Многоверсионность
- Задача очистки

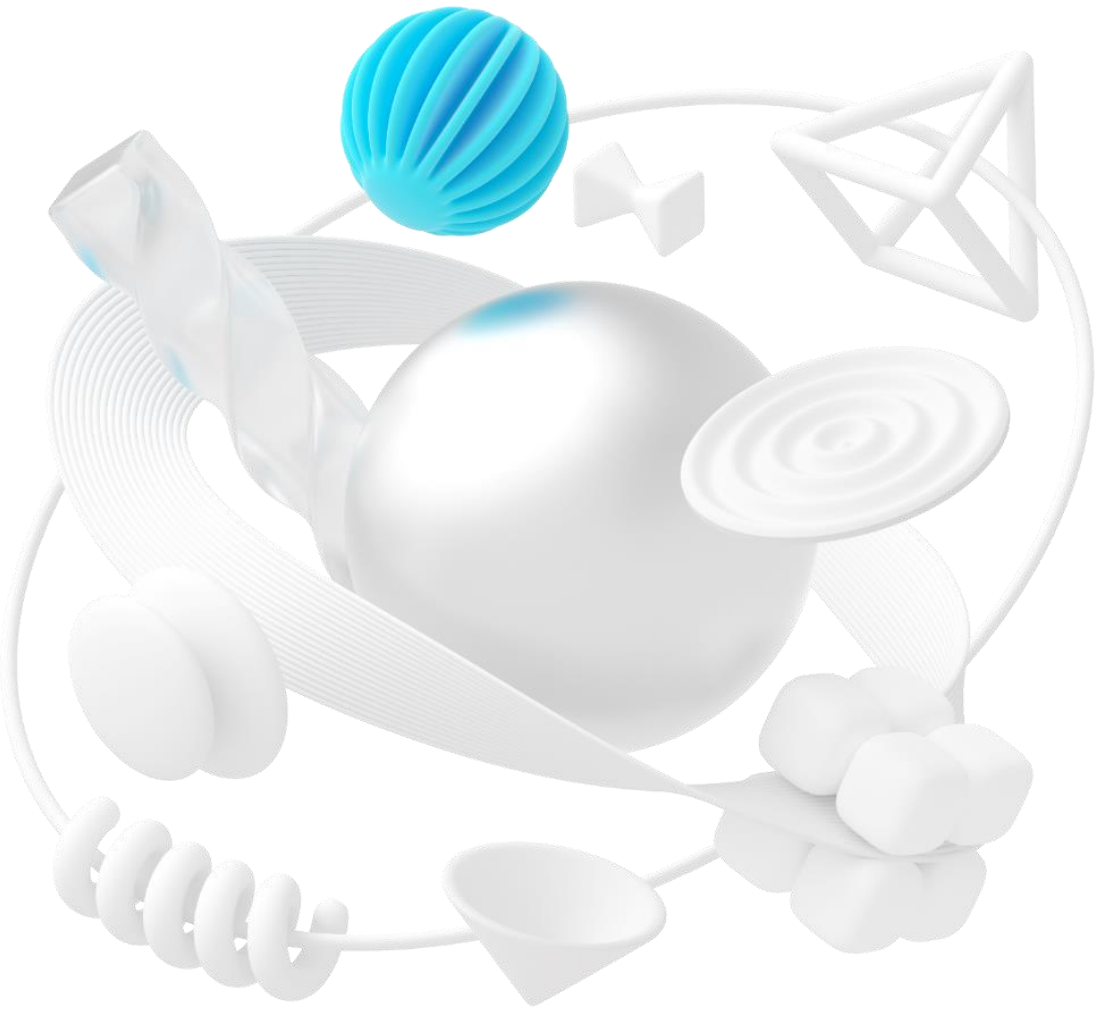

Итоги

ЦИФРОВАЯ АКАДЕМИЯ

1. Установите параметры сервера
2. Перезапустите экземпляр
3. Установите стандартную схему pgbench, измерьте ее размер
4. Запустите нагрузочный тест с помощью pgbench
5. Спровоцируйте блоатинг таблиц схемы pgbench, измерьте размер таблиц и индексов pgbench
6. Повторите нагрузочный тест
7. Посмотрите процессы экземпляра
8. Выполните аварийное завершение экземпляра, запустите его вновь, найдите записи в журнале,
9. Запретите подключение приложения
10. Выполните перестроение объектов pgbench, измерьте размер таблиц и индексов pgbench
11. Разрешите подключение приложений
12. Повторите нагрузочный тест

ЦИФРОВАЯ АКАДЕМИЯ
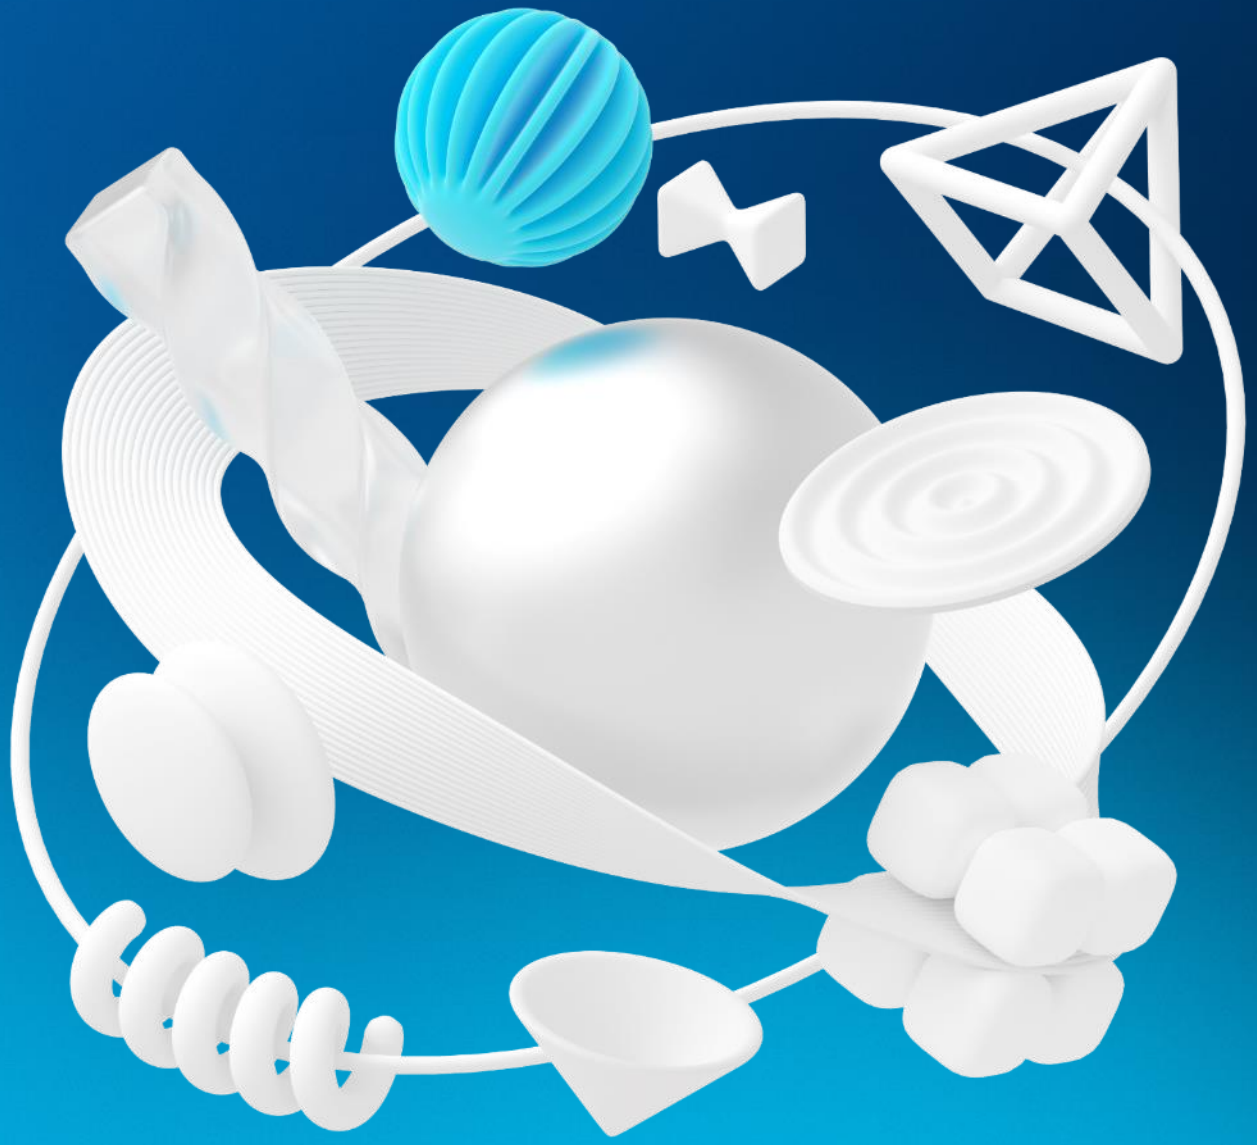
СПАСИБО